

Análisis de Series de Tiempo para la Precipitación en Puebla

Heriberto Espino Montelongo - 175199

Universidad de las Américas Puebla

P25-LEC4032-2: Econometría II

Dra. Daniela Cortés Toto

30 de abril de 2025

Índice

1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Objetivo general	2
1.3. Objetivos específicos	2
1.4. Justificación	2
1.5. Hipótesis	3
2. Desarrollo	4
2.1. Partición de la Serie para su Análisis	5
2.2. Serie Sin Transformaciones	5
2.3. Diferencias Estacionales de la Serie Sin Transformar	6
2.3.1. Primera Diferencia Estacional	6
2.3.2. Segunda Diferencia Estacional	8
2.3.3. Tercera Diferencia Estacional	9
2.3.4. Comparación de Desviaciones Estándar con Distintas Diferencias . . .	10
2.4. Serie con Transformación	11
2.4.1. Estimación Puntual de λ	11
2.4.2. Intervalo de Confianza	12
2.4.3. Serie Transformada	12
2.5. Diferencias Estacionales de la Serie con Transformación	14
2.5.1. Primera Diferencia Estacional	14
2.5.2. Segunda Diferencia Estacional	15
2.5.3. Tercera Diferencia Estacional	16
2.5.4. Comparación de Desviaciones Estándar con Distintas Diferencias . . .	17
2.6. Modelado	18
2.6.1. Serie sin Transformaciones	18
2.6.2. Serie Transformada	26
2.7. Modelos Propuestos	27
2.7.1. Primer Modelo para la Serie Sin Transformar	27
2.7.2. Segundo Modelo para la Serie Sin Transformar	31
2.7.3. Tercer Modelo para la Serie Sin Transformar	35
2.7.4. Cuarto Modelo para la Serie Sin Transformar	39
2.7.5. Primer Modelo Propuesto para la Serie Transformada	40
2.7.6. Segundo Modelo Propuesto para la Serie Transformada	42
2.8. Modelo Seleccionado	46

2.9. Pronóstico	48
2.9.1. Método Forecast	48
2.9.2. Pronóstico Óptimo	51
2.10. Actualización de Pronóstico	57
2.10.1. Método Forecast	57
2.10.2. Actualización de Pronóstico	58
2.10.3. Comparación	59
3. Conclusiones	60
4. Referencias	61

1 Introducción

La precipitación es un elemento fundamental del clima que influye directamente en la disponibilidad de agua, la planificación urbana y la actividad económica y social de la ciudad. En regiones como Puebla, donde se combina una diversidad climática con una fuerte dependencia de los recursos hídricos, entender los patrones de precipitación se vuelve crucial para una adecuada toma de decisiones en múltiples sectores. En este trabajo se realiza un análisis estadístico de la precipitación mensual registrada en la estación meteorológica Puebla (DGE), ubicada en las coordenadas 19.0000°N , 98.1833°O . Los datos fueron obtenidos del repositorio de la National Oceanic and Atmospheric Administration (NOAA) y abarcan el periodo comprendido entre septiembre de 1952 y diciembre de 2009. A partir de esta serie histórica, se busca modelar los patrones de comportamiento estacional y de tendencia, así como generar pronósticos que permitan anticipar el comportamiento futuro de la precipitación en la región.

1.1 Planteamiento del problema

La precipitación es una variable climática de alta relevancia para el funcionamiento de los sistemas económicos, sociales, alimenticios, entre otros. Su variabilidad, tanto en magnitud como en frecuencia, puede tener efectos significativos sobre la economía local, el bienestar social y la sostenibilidad de los ecosistemas urbanos y rurales. Los cambios abruptos o sostenidos en los patrones de precipitación pueden derivar en fenómenos extremos como sequías prolongadas o inundaciones severas, afectando directamente la producción agrícola, la disponibilidad de agua potable, el funcionamiento de la infraestructura hidráulica y la salud pública.

En contextos urbanos, una precipitación intensa y mal gestionada puede colapsar los sistemas de drenaje, deteriorar la infraestructura vial, aumentar la vulnerabilidad de asentamientos irregulares y agravar condiciones socioeconómicas preexistentes. En entornos rurales, la dependencia directa de la lluvia para actividades agropecuarias implica que cualquier alteración en los patrones de precipitación puede traducirse en pérdidas económicas, inseguridad alimentaria y desplazamientos poblacionales.

Dado que la precipitación muestra una estructura temporal compleja con componentes estacionales y posibles tendencias de largo plazo, es fundamental desarrollar modelos que permitan describir su comportamiento histórico y anticipar su evolución futura. Estas herramientas son clave para mejorar la toma de decisiones en sectores sensibles al clima, optimizar la asignación de recursos hídricos, diseñar políticas públicas resilientes y fortalecer la planificación territorial frente a escenarios de cambio climático.

En este contexto, surge la siguiente pregunta de investigación: *¿Cómo se ha comportado la precipitación mensual en Puebla y qué tipo de modelo es más adecuado para explicar su dinámica temporal y generar predicciones confiables para los años siguientes?*

1.2 Objetivo general

Desarrollar un análisis para la serie de tiempo de la precipitación mensual en Puebla (1952–2009), con el propósito de caracterizar su dinámica histórica, incluyendo patrones estacionales, tendencias de largo plazo y eventos extremos, y proponer un modelo que ofrezca pronósticos confiables, contribuyendo así a la toma de decisiones en sectores sociales y económicos sensibles a la variabilidad climática.

1.3 Objetivos específicos

Para alcanzar el objetivo general, se propone navegar por distintas metodologías y comparar los resultados. Se buscará identificar patrones estacionales u otro tipo de tendencias. Con base en estas características, se probarán distintos modelos, como modelos ARIMA con componentes estacionales, con el objetivo de encontrar el que mejor se ajuste a los datos observados. Una vez seleccionado el modelo óptimo, se procederá a realizar pronósticos sobre el comportamiento de la precipitación.

1.4 Justificación

La precipitación es un factor climático fundamental que incide directamente en múltiples dinámicas sociales y económicas. Su variabilidad temporal y espacial afecta de manera significativa sectores estratégicos como la agricultura, la gestión de los recursos hídricos, la planificación territorial y la prevención de desastres naturales. Como ejemplos se encuentran la producción agrícola, que depende de las lluvias, lo que condiciona tanto el rendimiento como la viabilidad de distintos cultivos; de igual forma, la infraestructura hidráulica y los sistemas de abastecimiento de agua, que requieren de una planificación precisa basada en patrones de precipitación confiables.

Ante este panorama, se busca desarrollar una herramienta que permita describir y predecir el comportamiento mensual de la precipitación. Teniendo como propósito mejorar la toma de decisiones en sectores sensibles al clima, facilitando la formulación de toma de decisiones, fortaleciendo la capacidad de respuesta y adaptación ante eventos extremos, como sequías prolongadas o lluvias torrenciales que derivan en inundaciones.

1.5 Hipótesis

Se plantea la hipótesis de que la precipitación mensual en la ciudad de Puebla tiene una periodicidad anual (o de cada doce meses), así como una posible estabilidad en su tendencia de largo plazo, sujeta a perturbaciones atribuibles a la variabilidad climática y a la ocurrencia de fenómenos extremos. Se espera, además, una fuerte dependencia temporal, en la cual los valores actuales de precipitación están correlacionados con observaciones previas, tanto de meses recientes como de años anteriores. Bajo este supuesto, se considera que un modelo ARIMA con componentes estacionales será adecuado para capturar la estructura temporal de la serie, modelar sus componentes, y generar predicciones con utilidad práctica para la toma de decisiones sensibles respecto a aspectos climáticos.

2 Desarrollo

Para estudiar el comportamiento de la precipitación en la ciudad de Puebla a lo largo del tiempo, se analizará una serie mensual que representa los niveles de precipitación acumulada por mes en milímetros. Esta información fue recopilada por la NOAA a través de su red de estaciones climatológicas, en particular la estación identificada como Puebla (DGE). El periodo que abarca la serie es de septiembre de 1952 a diciembre de 2009. A continuación, se muestra el gráfico de la precipitación mensual durante todo el periodo observado.




Figura 1: *Elaboración Propia*. Descripción de la imagen.

Para una mejor visualización se muestran los últimos 10 años de la serie




Figura 2: *Elaboración Propia*. Descripción de la imagen.

Como puede apreciarse, los p-valores presentan una marcada estacionalidad, con picos de precipitación concentrados en los meses de verano, durante el principio de la segunda mitad de cada año. Esta estacionalidad responde a los ciclos climáticos típicos de la región central de México, donde predominan las lluvias en la temporada de verano.

2.1 Partición de la Serie para su Análisis

Antes de comenzar a trabajar con la serie temporal, y considerando que uno de los objetivos principales de este trabajo es la actualización del pronóstico y la comparación de resultados, no serán utilizados los últimos 12 meses de la serie. Es importante destacar que a partir de este momento solo se trabajará con esta porción de la serie, hasta que se generen los pronósticos y únicamente será utilizada en modo de comparación con los datos de la serie original, posteriormente, actualizaremos el pronóstico y repetiremos la comparación.

2.2 Serie Sin Transformaciones

En esta sección se analiza la serie original de precipitación mensual sin aplicar transformaciones, más allá de la estandarización, que no cambia la distribución de los datos. La estandarización se realizó con el objetivo de facilitar la comparación con modelos entrenados sobre versiones transformadas de la serie, asegurando así que métricas como el log-likelihood y el AIC sean directamente comparables entre modelos.

Verificación de Estacionariedad de la Serie

Para verificar la estacionariedad de la serie de precipitación mensual en Puebla, se aplicó la prueba de Dickey-Fuller aumentada (ADF). El resultado obtenido fue:

- El estadístico de prueba es -6.15,
- El p-valor es $7,58 \times 10^{-8}$,
- Los valores críticos a los niveles del 1 %, 5 % y 10 % son -3.44, -2.86 y -2.57.

Dado que el p-valor es mucho menor que 0.05, se rechaza la hipótesis nula. Esto indica que la serie de precipitación mensual en Puebla es estacionaria, por lo que no sería necesario aplicar diferenciación o transformaciones.

Autocorrelaciones Simples y Autocorrelaciones Parciales

Los gráficos de Autocorrelaciones Simples (FAC) y Autocorrelaciones Parciales (FACP) muestran el comportamiento de la serie de tiempo de precipitación mensual en Puebla, con un retraso de hasta 48 observaciones. En el caso de la FAC, se observa que las autocorrelaciones no decaen rápidamente, lo que sugiere que la serie tiene una dependencia temporal significativa en varios retrasos. Esto puede indicar que la serie no es completamente estacionaria y se justifica la necesidad de aplicar una diferencia estacional.

Los valores significativos de autocorrelación para la serie original fueron los siguientes:




Figura 3: *Elaboración Propia*. FAC y FACP de la serie de Precipitación Mensual en Puebla

■ r_1 : 0.511	■ r_6 : -0.577	■ r_{11} : 0.524	■ r_{16} : -0.319	■ r_{22} : 0.301
■ r_2 : 0.238	■ r_7 : -0.454	■ r_{12} : 0.617	■ r_{17} : -0.514	■ r_{23} : 0.503
■ r_4 : -0.311	■ r_8 : -0.244	■ r_{13} : 0.424	■ r_{18} : -0.528	
■ r_5 : -0.529	■ r_{10} : 0.296	■ r_{14} : 0.183	■ r_{19} : -0.419	■ r_{24} : 0.563

Mientras que para las autocorrelaciones parciales los valores significativos fueron:

■ ρ_1 : 0.512	■ ρ_5 : -0.339	■ ρ_8 : -0.082	■ ρ_{19} : -0.092
■ ρ_3 : -0.137	■ ρ_6 : -0.270	■ ρ_{11} : 0.194	
■ ρ_4 : -0.356	■ ρ_7 : -0.137	■ ρ_{12} : 0.250	■ ρ_{24} : 0.124

2.3 Diferencias Estacionales de la Serie Sin Transformar

Aunque la serie fue declarada estacionaria mediante la prueba ADF en su forma original, las autocorrelaciones simples decrecían muy lentamente, lo cual sugiere la presencia de estacionalidad.

2.3.1 Primera Diferencia Estacional

Se aplicó una diferencia estacional de orden $D = 1$ con periodicidad anual $s = 12$:

$$\nabla_{12}X_t = X_t - X_{t-12}$$

Esta transformación busca eliminar la estacionalidad anual observada en la serie, resultando en la siguiente:

Verificación de Estacionariedad de la Serie




Figura 4: *Elaboración Propia*. Primera Diferencia Estacional, Precipitación Mensual en Puebla

La serie resultante, fue evaluada nuevamente con la prueba de Dickey-Fuller aumentada, obteniendo los siguientes resultados:

- Estadístico ADF: -10.8714
- p-valor: $1,36 \times 10^{-19}$
- Valores críticos: -3.44 (1 %), -2.86 (5 %), -2.57 (10 %)

Dado que el p-valor es menor a cualquier nivel de significancia, se rechaza la hipótesis nula de no estacionariedad. Por tanto, concluimos que la serie diferenciada es estacionaria.

Autocorrelaciones Simples y Autocorrelaciones Parciales

Para analizar la dependencia temporal en la serie, se graficaron la FAC y la FACP de la serie:




Figura 5: *Elaboración Propia*. FAC y FACP de la Primera Diferencia Estacional

Los valores significativos de autocorrelación para la primera diferencia estacional fueron los siguientes:

- r_1 : 0.085 ■ r_{12} : -0.414 ■ r_{73} : -0.113
- r_5 : -0.095 ■ r_{69} : 0.138 ■ r_{82} : -0.099

Mientras que para las autocorrelaciones parciales los valores significativos fueron:

- ρ_1 : 0.085 ■ ρ_{24} : -0.301 ■ ρ_{57} : -0.092 ■ ρ_{72} : -0.095
- ρ_5 : -0.084 ■ ρ_{29} : -0.102 ■ ρ_{60} : -0.124 ■ ρ_{82} : -0.080
- ρ_{12} : -0.436 ■ ρ_{36} : -0.160 ■ ρ_{61} : 0.138 ■ ρ_{85} : -0.082
- ρ_{17} : -0.120 ■ ρ_{48} : -0.140 ■ ρ_{69} : 0.103 ■ ρ_{93} : 0.092

Esto indica que, si bien, la diferencia estacional eliminó la mayor parte de la dependencia temporal, persisten algunos retrasos con influencia significativa, lo cual será considerado en el ajuste del modelo ARIMA. También se comparará con otras diferencias.

2.3.2 Segunda Diferencia Estacional

Tras aplicar una segunda diferencia estacional con periodicidad $s = 12$ a la serie estandarizada (es decir, $\nabla_{12}^2 T(X_t)$), se analizó la estructura de autocorrelación para identificar patrones significativos en la nueva serie.




Figura 6: *Elaboración Propia*. FAC y FACP de la serie de precipitación mensual en Puebla, estandarizada y con segunda diferencia estacional ($D = 2$, $s = 12$).

Los valores significativos de autocorrelación para la segunda diferencia estacional fueron los siguientes:

- r_1 : 0.085 ■ r_{12} : -0.414 ■ r_{73} : -0.113
- r_5 : -0.095 ■ r_{69} : 0.138 ■ r_{82} : -0.099

Mientras que para las autocorrelaciones parciales los valores significativos fueron:

▪ ρ_1 : 0.085	▪ ρ_{24} : -0.301	▪ ρ_{57} : -0.092	▪ ρ_{72} : -0.095	▪ ρ_{109} : 0.096
▪ ρ_5 : -0.084	▪ ρ_{29} : -0.102	▪ ρ_{60} : -0.124	▪ ρ_{82} : -0.080	▪ ρ_{113} : -0.091
▪ ρ_{12} : -0.436	▪ ρ_{36} : -0.160	▪ ρ_{61} : 0.138	▪ ρ_{85} : -0.082	▪ ρ_{119} : 0.092
▪ ρ_{17} : -0.120	▪ ρ_{48} : -0.140	▪ ρ_{69} : 0.103	▪ ρ_{93} : 0.092	▪ ρ_{120} : -0.136

2.3.3 Tercera Diferencia Estacional

Se aplicó una tercera diferencia estacional con periodicidad $s = 12$ a la serie estandarizada de precipitación mensual.




Figura 7: *Elaboración Propia*. FAC y FACP de la serie de precipitación mensual en Puebla, estandarizada y con tercera diferencia estacional ($D = 3$, $s = 12$).

Los valores significativos de autocorrelación fueron los siguientes:

▪ r_{12} : -0.699	▪ r_{24} : 0.191	▪ r_{57} : -0.131	▪ r_{69} : 0.182	▪ r_{81} : -0.145
---------------------	--------------------	---------------------	--------------------	---------------------

Mientras que para las autocorrelaciones parciales los valores significativos fueron:

▪ ρ_{12} : -0.713	▪ ρ_{48} : -0.493	▪ ρ_{58} : -0.411	▪ ρ_{62} : 6.763	▪ ρ_{107} : -9.436
▪ ρ_{24} : -0.617	▪ ρ_{52} : 0.345	▪ ρ_{59} : 1.475	▪ ρ_{67} : -2.332	▪ ρ_{114} : 5.771
▪ ρ_{36} : -0.517	▪ ρ_{54} : 0.331	▪ ρ_{60} : 3.447	▪ ρ_{95} : -6.078	▪ ρ_{116} : 3.639

Se observa una cantidad considerable de retrasos con valores extremos (por ejemplo, $\rho_{107} = -9,436$ y $\rho_{62} = 6,763$), lo que sugiere un posible sobrediferenciamiento, que genera ruido excesivo y sobreajuste en la estructura temporal.

2.3.4 Comparación de Desviaciones Estándar con Distintas Diferencias

Para evaluar el efecto de las diferencias estacionales sobre la variabilidad de la serie, se comparó la desviación estándar de la serie estandarizada y sus versiones diferenciadas con $D = 1$, $D = 2$ y $D = 3$:




Figura 8: *Elaboración Propia*. Desviación estándar de la serie estandarizada y con diferencias estacionales de primer, segundo y tercer orden.

Se observa que la serie con menor varianza corresponde a aquella a la que se le aplicó una primera diferencia estacional. Cabe recordar que la serie original tiene varianza unitaria, ya que fue estandarizada previamente. Aunque la aplicación de diferencias estacionales tiende a reducir la varianza, el uso de tres diferencias puede resultar excesivo, lo cual se evidencia en la aparición de valores extremos en la Función de Autocorrelación Parcial (FACP), así como en la posible pérdida de estructura significativa para el modelado. Por lo tanto, se opta por conservar únicamente la primera diferencia estacional, ya que no solo presenta la menor varianza entre las transformaciones consideradas, sino que además tiene una estructura más interpretable en su Función de Autocorrelación.

2.4 Serie con Transformación

Se utilizó la transformación Yeo-Johnson para aproximar la normalidad de los datos, lo que permite que los modelos ajustados sean más robustos y que las inferencias estadísticas sean confiables, además de ayudar a estabilizar la varianza. Esta transformación se eligió porque existen meses con precipitación igual a cero, un caso donde la transformación Box-Cox no es aplicable. Yeo-Johnson acepta valores cero sin necesidad de modificar los datos con constantes arbitrarias, preservando así su integridad y significado original.

La precipitación es una variable altamente sesgada, con muchos meses de poca o ninguna lluvia y pocos meses con lluvias abundantes. Esta transformación corrige la asimetría y acerca la distribución a una normal, mejorando los supuestos de los modelos estadísticos y aumentando la precisión en predicciones y simulaciones.

Además, la precipitación presenta varianza heterogénea, con meses en que la lluvia varía mucho respecto a otros. La transformación Yeo-Johnson contribuye a esta estabilización de la varianza.

A continuación, se muestra la definición matemática de la transformación Yeo-Johnson, como se encuentra en la literatura estadística (propuesta por Ingram Olkin y I. Paul Yeo & R. J. Johnson en 2000).

Sea $x \in \mathbb{R}$. La transformación $T(x; \lambda)$ se define como:

$$T(x; \lambda) = \begin{cases} \frac{[(x+1)^\lambda - 1]}{\lambda} & \text{si } x \geq 0, \lambda \neq 0 \\ \log(x + 1) & \text{si } x \geq 0, \lambda = 0 \\ -\frac{[(-x+1)^{2-\lambda} - 1]}{2-\lambda} & \text{si } x < 0, \lambda \neq 2 \\ -\log(-x + 1) & \text{si } x < 0, \lambda = 2 \end{cases}$$

2.4.1 Estimación Puntual de λ

Se utilizó la librería de `sklearn` para estimar el parámetro λ mediante máxima verosimilitud. El valor estimado fue:

$$\hat{\lambda} = 0,2385$$

2.4.2 Intervalo de Confianza

Se aplicó un procedimiento de bootstrap con 1000 réplicas para construir un intervalo de confianza del 95 % para λ . El intervalo obtenido fue:

$$IC_{95\%}(\lambda) = (0,2097, 0,2693)$$




Figura 9: *Elaboración Propia*. Distribución bootstrap del parámetro λ para la transformación de Yeo-Johnson.

2.4.3 Serie Transformada

Una vez aplicada la transformación de Yeo-Johnson estandarizada a la serie original de precipitación mensual, se obtiene la siguiente representación gráfica en la Figura 10.

Verificación de Estacionariedad de la Serie

Para verificar la estacionariedad de la serie transformada con Yeo-Johnson, se aplicó la prueba de Dickey-Fuller aumentada (ADF). Los resultados fueron los siguientes:

- Estadístico ADF: -6.885
- p-valor: $1,36 \times 10^{-9}$
- Valores críticos: -3.44 (1 %), -2.86 (5 %), -2.57 (10 %)

Dado que el estadístico ADF es menor que los valores críticos a todos los niveles y el p-valor es significativamente menor que $\alpha = 0,05$, se concluye que la serie transformada es estacionaria.

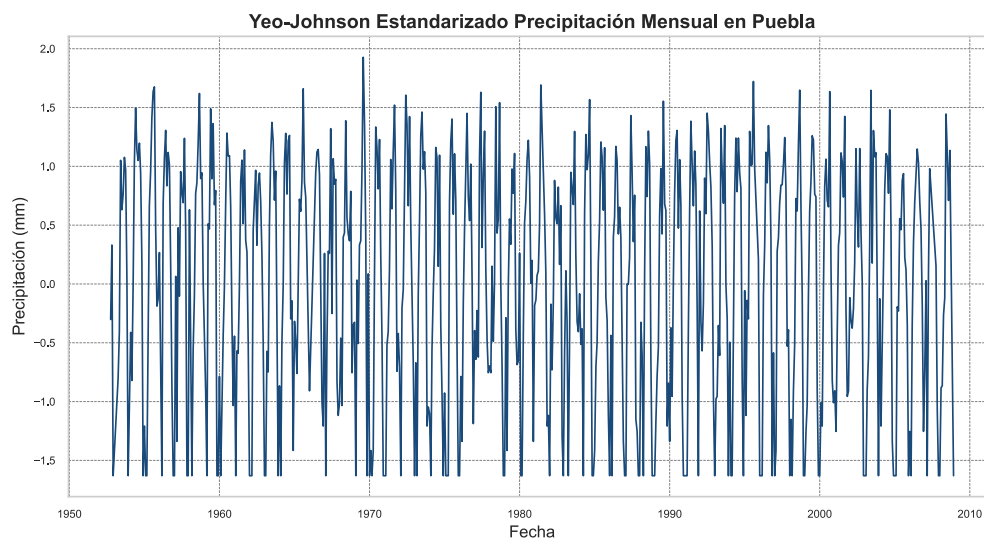


Figura 10: *Elaboración Propia*. Serie de precipitación mensual en Puebla transformada con Yeo-Johnson y estandarizada.

Autocorrelaciones Simples y Autocorrelaciones Parciales

A continuación, se presentan las funciones de autocorrelación (FAC) y autocorrelación parcial (FACP) de la serie transformada de precipitación mensual:




Figura 11: *Elaboración Propia*. FAC y FACP de la serie transformada (Yeo-Johnson) de precipitación mensual en Puebla.

También podemos notar un patrón estacional, igual que en el caso pasado, por lo que se aplicará la misma metodología, aplicar diferencias estacionales y comparar.

2.5 Diferencias Estacionales de la Serie con Transformación

En esta sección se comparan las diferentes diferencias estacionales que se le pueden aplicar a la serie, con la que posteriormente entrenaremos al modelo.

2.5.1 Primera Diferencia Estacional

Los valores significativos de autocorrelación fueron los siguientes:




Figura 12: *Elaboración Propia*. FAC y FACP de la Primera Diferencia Estacional

Los valores significativos de autocorrelación fueron los siguientes:

- r_1 : 0.188
- r_6 : -0.100
- r_{33} : 0.098
- r_2 : 0.126
- r_{12} : -0.402
- r_{45} : -0.120

Los valores significativos de autocorrelación parcial fueron los siguientes:

- ρ_1 : 0.188
- ρ_{22} : -0.084
- ρ_{42} : -0.118
- ρ_{72} : -0.130
- ρ_{113} : -0.086
- ρ_2 : 0.094
- ρ_{24} : -0.281
- ρ_{46} : -0.094
- ρ_{78} : -0.080
- ρ_{118} : -0.082
- ρ_6 : -0.085
- ρ_{25} : 0.108
- ρ_{48} : -0.167
- ρ_{84} : -0.080
- ρ_{120} : -0.116
- ρ_{12} : -0.432
- ρ_{30} : -0.097
- ρ_{50} : 0.092
- ρ_{92} : -0.140
- ρ_{13} : 0.081
- ρ_{33} : 0.111
- ρ_{55} : 0.093
- ρ_{93} : 0.116
- ρ_{17} : -0.114
- ρ_{36} : -0.146
- ρ_{60} : -0.100
- ρ_{94} : -0.122

Verificar Estacionariedad en la Serie

- Estadístico ADF: -9.030
- p-valor: $5,46 \times 10^{-15}$
- Valores críticos: -3.44 (1 %), -2.87 (5 %), -2.57 (10 %)

El estadístico ADF es $-9,030$, valor muy por debajo de todos los umbrales críticos y el p-valor es $5,46 \times 10^{-15}$, muchísimo menor que cualquier nivel de significancia. Por lo que se rechaza la hipótesis nula, es decir, la serie es estacionaria.

2.5.2 Segunda Diferencia Estacional

Así se ve la FAC y la FACP de la segunda diferencia estacional de la serie transformada:




Figura 13: *Elaboración Propia*. FAC y FACP de la Segunda Diferencia Estacional de la Serie Transformada

Los valores significativos de autocorrelación fueron los siguientes:

- r_1 : 0.151 ■ r_{12} : -0.618 ■ r_{33} : 0.129 ■ r_{46} : -0.112
- r_2 : 0.095 ■ r_{13} : -0.115 ■ r_{45} : -0.137

Los valores significativos de autocorrelación parcial fueron los siguientes:

- ρ_1 : 0.151 ■ ρ_{54} : -0.121 ■ ρ_{75} : 0.276 ■ ρ_{89} : -0.081 ■ ρ_{111} : -0.513
- ρ_{12} : -0.630 ■ ρ_{58} : -0.097 ■ ρ_{76} : -0.498 ■ ρ_{92} : 0.125 ■ ρ_{112} : 0.092
- ρ_{14} : 0.102 ■ ρ_{60} : -0.172 ■ ρ_{77} : 0.946 ■ ρ_{93} : -0.104 ■ ρ_{113} : 0.376
- ρ_{22} : -0.103 ■ ρ_{61} : 0.127 ■ ρ_{78} : -19.481 ■ ρ_{95} : -0.089 ■ ρ_{114} : -0.795
- ρ_{24} : -0.493 ■ ρ_{64} : -0.084 ■ ρ_{79} : -1.053 ■ ρ_{96} : -0.083 ■ ρ_{115} : 1.170
- ρ_{25} : 0.127 ■ ρ_{66} : -0.133 ■ ρ_{80} : 0.617 ■ ρ_{98} : 0.205 ■ ρ_{116} : -5.319
- ρ_{36} : -0.317 ■ ρ_{67} : 0.108 ■ ρ_{81} : -0.368 ■ ρ_{99} : -0.194 ■ ρ_{117} : -2.444
- ρ_{37} : 0.123 ■ ρ_{70} : -0.182 ■ ρ_{82} : 0.198 ■ ρ_{102} : -0.129 ■ ρ_{118} : 1.410
- ρ_{42} : -0.117 ■ ρ_{71} : 0.154 ■ ρ_{83} : -0.110 ■ ρ_{104} : 0.191 ■ ρ_{119} : -0.889
- ρ_{46} : -0.120 ■ ρ_{72} : -0.284 ■ ρ_{85} : -0.144 ■ ρ_{105} : -0.293 ■ ρ_{120} : 0.451
- ρ_{48} : -0.270 ■ ρ_{73} : 0.288 ■ ρ_{86} : 0.254 ■ ρ_{108} : -0.188
- ρ_{50} : 0.082 ■ ρ_{74} : -0.265 ■ ρ_{87} : -0.193 ■ ρ_{110} : 0.309

2.5.3 Tercera Diferencia Estacional

Así se ve la FAC y la FACP de la tercera diferencia estacional de la serie transformada:




Figura 14: *Elaboración Propia*. FAC y FACP de la Tercera Diferencia Estacional de la Serie Transformada

Los valores significativos de autocorrelación fueron los siguientes:

- | | | | |
|---------------------|---------------------|--------------------|---------------------|
| ■ r_1 : 0.141 | ■ r_{12} : -0.701 | ■ r_{24} : 0.211 | ■ r_{34} : 0.124 |
| ■ r_{11} : -0.086 | ■ r_{13} : -0.123 | ■ r_{33} : 0.148 | ■ r_{45} : -0.138 |

Los valores significativos de autocorrelación parcial fueron los siguientes:

- | | | | | |
|------------------------|------------------------|------------------------|-------------------------|-------------------------|
| ■ ρ_1 : 0.142 | ■ ρ_{55} : 0.216 | ■ ρ_{72} : -5.899 | ■ ρ_{87} : 1.212 | ■ ρ_{103} : 0.254 |
| ■ ρ_{11} : -0.086 | ■ ρ_{56} : -0.195 | ■ ρ_{73} : -1.320 | ■ ρ_{88} : 0.515 | ■ ρ_{104} : -0.210 |
| ■ ρ_{12} : -0.715 | ■ ρ_{58} : -0.223 | ■ ρ_{74} : -0.677 | ■ ρ_{89} : 0.246 | ■ ρ_{105} : 0.313 |
| ■ ρ_{14} : 0.102 | ■ ρ_{59} : 0.252 | ■ ρ_{75} : 0.525 | ■ ρ_{90} : 0.528 | ■ ρ_{107} : 0.121 |
| ■ ρ_{21} : -0.097 | ■ ρ_{60} : -0.738 | ■ ρ_{76} : -0.282 | ■ ρ_{92} : 0.331 | ■ ρ_{109} : 0.104 |
| ■ ρ_{22} : -0.120 | ■ ρ_{61} : 2.254 | ■ ρ_{77} : -0.452 | ■ ρ_{93} : 0.115 | ■ ρ_{110} : -0.172 |
| ■ ρ_{24} : -0.591 | ■ ρ_{62} : 1.650 | ■ ρ_{78} : 0.301 | ■ ρ_{94} : 0.212 | ■ ρ_{111} : 0.265 |
| ■ ρ_{25} : 0.116 | ■ ρ_{63} : -0.697 | ■ ρ_{79} : -0.416 | ■ ρ_{95} : -0.129 | ■ ρ_{112} : -0.116 |
| ■ ρ_{36} : -0.426 | ■ ρ_{64} : 0.397 | ■ ρ_{80} : -0.119 | ■ ρ_{96} : 0.514 | ■ ρ_{114} : 0.185 |
| ■ ρ_{37} : 0.187 | ■ ρ_{65} : -0.212 | ■ ρ_{81} : -0.154 | ■ ρ_{97} : -0.619 | ■ ρ_{115} : 0.108 |
| ■ ρ_{42} : -0.173 | ■ ρ_{66} : -0.205 | ■ ρ_{82} : -0.292 | ■ ρ_{98} : 1.710 | ■ ρ_{116} : -0.159 |
| ■ ρ_{46} : -0.113 | ■ ρ_{68} : 0.236 | ■ ρ_{83} : -0.493 | ■ ρ_{99} : 2.121 | ■ ρ_{117} : 0.378 |
| ■ ρ_{48} : -0.397 | ■ ρ_{69} : -0.819 | ■ ρ_{84} : -0.150 | ■ ρ_{100} : -0.606 | ■ ρ_{118} : -0.124 |
| ■ ρ_{49} : 0.174 | ■ ρ_{70} : 1.301 | ■ ρ_{85} : -0.893 | ■ ρ_{101} : 0.461 | ■ ρ_{120} : 0.206 |
| ■ ρ_{54} : -0.327 | ■ ρ_{71} : 1.432 | ■ ρ_{86} : -5.929 | ■ ρ_{102} : -0.157 | |

2.5.4 Comparación de Desviaciones Estándar con Distintas Diferencias




Figura 15: *Elaboración Propia*. Desviación estándar de la serie transformada y estandarizada, con diferencias estacionales de primer, segundo y tercer orden.

Ocurre lo mismo que en las diferencias de la serie sin transformaciones, Tal como se observó en el caso de las diferencias aplicadas a la serie original sin transformaciones, el comportamiento de la desviación estándar se ve afectado por el orden de la diferencia estacional. Se observa que la menor varianza corresponde a la serie con una primera diferencia estacional. En consecuencia, se decide conservar únicamente la primera diferencia estacional. Es interesante notar que con la transformación y las diferencias, las autocorrelaciones parciales simples aumentan notablemente en cantidad, a comparación de las autocorrelaciones parciales de la serie sin transformación, tal vez la transformación no era la adecuada para el objetivo de modelado.

2.6 Modelado

En esta sección se muestra el proceso de modelado para la serie transformada y para la serie sin transformar.

2.6.1 Serie sin Transformaciones

Para la serie sin transformaciones, se hizo un modelado donde se realizaron 252 modelos con diferentes hiperparámetros y se seleccionaba el modelo que tenía el menor AIC.

Primero se intentó con la librería pmdarima, que realiza distintas combinaciones hasta orden dos, obteniendo estos resultados:

```
(1) ARIMA(1,0,0)(0,1,1)[12], AIC=1430.397
(2) ARIMA(0,0,1)(0,1,1)[12], AIC=1431.266
(3) ARIMA(1,0,1)(0,1,1)[12], AIC=1432.133
(4) ARIMA(2,0,0)(0,1,1)[12], AIC=1432.157
(5) ARIMA(1,0,0)(0,1,2)[12], AIC=1432.368
(6) ARIMA(1,0,0)(1,1,1)[12], AIC=1432.373
(7) ARIMA(0,0,2)(0,1,1)[12], AIC=1432.664
(8) ARIMA(0,0,1)(0,1,2)[12], AIC=1433.240
(9) ARIMA(0,0,1)(1,1,1)[12], AIC=1433.245
(10) ARIMA(2,0,1)(0,1,1)[12], AIC=1434.127
(11) ARIMA(0,0,0)(0,1,1)[12], AIC=1445.334
(12) ARIMA(1,0,0)(1,1,0)[12], AIC=1523.141
(13) ARIMA(0,0,1)(1,1,0)[12], AIC=1523.219
(14) ARIMA(0,0,1)(0,1,0)[12], AIC=1652.849
(15) ARIMA(1,0,0)(0,1,0)[12], AIC=1652.984
(16) ARIMA(0,0,0)(0,1,0)[12], AIC=1655.671
```

Listing 1: Modelos con pmdarima

Sin embargo, ninguno cumplió los supuestos en los residuos, por lo que se decidió no usar la librería e ir a ordenes mayores. También, para poder visualizar los resultados en base a su AIC, se fueron variando dos hiperparámetros, es decir, entre p, q, P, Q , dos se fijaban con un valor de cero, y se calculaba el AIC para distintos modelos recorriendo los valores que no estaban fijos. Es decir:

- Se fijan los valores de $\text{ARIMA}(p, 0, q) \times (0, 1, 0, 12)$ donde $p = 0, 1, 2, \dots$ y $q = 0, 1, 2, \dots$
- Se fijan los valores de $\text{ARIMA}(0, 0, q) \times (P, 1, 0, 12)$ donde $P = 0, 1, 2, \dots$ y $q = 0, 1, 2, \dots$
- Se fijan los valores de $\text{ARIMA}(p, 0, 0) \times (0, 1, Q, 12)$ donde $p = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$
- Se fijan los valores de $\text{ARIMA}(0, 0, 0) \times (P, 1, Q, 12)$ donde $P = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$

Se fijan los valores de $\text{ARIMA}(p, 0, q) \times (0, 1, 0, 12)$ donde $p = 0, 1, 2, \dots$ y $q = 0, 1, 2, \dots$.

AIC para diferentes combinaciones de $\text{ARIMA}(p, 0, q) \times (0, 1, 0, 12)$




Figura 16: *Elaboración Propia*. AIC donde $p = 0, 1, 2, \dots$ y $q = 0, 1, 2, \dots$.

```
(1) ARIMA(12,0,0)(0,1,4)[12], AIC=1367.04
(2) ARIMA(13,0,0)(0,1,4)[12], AIC=1367.37
(3) ARIMA(12,0,0)(0,1,3)[12], AIC=1368.24
(4) ARIMA(12,0,0)(0,1,5)[12], AIC=1369.25
(5) ARIMA(0,0,15)(0,1,0)[12], AIC=1370.81
(6) ARIMA(0,0,15)(0,1,0)[12], AIC=1370.81
(7) ARIMA(0,0,12)(0,1,0)[12], AIC=1370.92
(8) ARIMA(0,0,12)(0,1,0)[12], AIC=1370.92
(9) ARIMA(15,0,0)(0,1,4)[12], AIC=1371.49
(10) ARIMA(3,0,12)(0,1,0)[12], AIC=1372.25
(11) ARIMA(0,0,16)(0,1,0)[12], AIC=1372.52
(12) ARIMA(1,0,15)(0,1,0)[12], AIC=1372.60
(13) ARIMA(1,0,12)(0,1,0)[12], AIC=1372.69
(14) ARIMA(0,0,13)(0,1,0)[12], AIC=1372.78
(15) ARIMA(0,0,12)(1,1,0)[12], AIC=1372.79
```

Listing 2: donde $p = 0, 1, 2, \dots$ y $q = 0, 1, 2, \dots$.

Parece que no hay una gran diferencia entre modelos luego de que q , la parte media móvil, es mayor a 12, siendo el mejor modelo un $\text{ARIMA}(12,0,0)(0,1,4)[12]$, con un $\text{AIC}=1367.04$.

Se fijan los valores de $\text{ARIMA}(0, 0, q) \times (P, 1, 0, 12)$ donde $P = 0, 1, 2, \dots$ y $q = 0, 1, 2, \dots$.

AIC para diferentes combinaciones de $\text{ARIMA}(0,0,q) \times (P,1,0,12)$




Figura 17: *Elaboración Propia*. AIC donde $q = 0, 1, 2, \dots$ y $P = 0, 1, 2, \dots$.

```
(1) ARIMA(12,0,0)(0,1,4)[12], AIC=1367.04
(2) ARIMA(13,0,0)(0,1,4)[12], AIC=1367.37
(3) ARIMA(12,0,0)(0,1,3)[12], AIC=1368.24
(4) ARIMA(12,0,0)(0,1,5)[12], AIC=1369.25
(5) ARIMA(0,0,15)(0,1,0)[12], AIC=1370.81
(6) ARIMA(0,0,15)(0,1,0)[12], AIC=1370.81
(7) ARIMA(0,0,12)(0,1,0)[12], AIC=1370.92
(8) ARIMA(0,0,12)(0,1,0)[12], AIC=1370.92
(9) ARIMA(15,0,0)(0,1,4)[12], AIC=1371.49
(10) ARIMA(3,0,12)(0,1,0)[12], AIC=1372.25
(11) ARIMA(0,0,16)(0,1,0)[12], AIC=1372.52
(12) ARIMA(1,0,15)(0,1,0)[12], AIC=1372.60
(13) ARIMA(1,0,12)(0,1,0)[12], AIC=1372.69
(14) ARIMA(0,0,13)(0,1,0)[12], AIC=1372.78
(15) ARIMA(0,0,12)(1,1,0)[12], AIC=1372.79
```

Listing 3: donde $q = 0, 1, 2, \dots$ y $P = 0, 1, 2, \dots$.

Por el costo computacional, en esta y las siguientes no se realiza una comparación tan granulada, sino que se van dando saltos, suponiendo que el AIC es parecido por zonas, se volvió a llegar al mismo resultado que en el anterior con un $\text{ARIMA}(12,0,0)(0,1,4)[12]$, que cuenta con un AIC de 1367.04.

Se fijan los valores de $\text{ARIMA}(p, 0, 0) \times (0, 1, Q, 12)$ donde $p = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$.

AIC para diferentes combinaciones de $\text{ARIMA}(p, 0, 0) \times (0, 1, Q, 12)$




Figura 18: *Elaboración Propia*. AIC donde $p = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$.

```
(1) ARIMA(12,0,0)(0,1,4)[12], AIC=1367.04
(2) ARIMA(13,0,0)(0,1,4)[12], AIC=1367.37
(3) ARIMA(12,0,0)(0,1,3)[12], AIC=1368.24
(4) ARIMA(12,0,0)(0,1,5)[12], AIC=1369.25
(5) ARIMA(0,0,15)(0,1,0)[12], AIC=1370.81
(6) ARIMA(0,0,15)(0,1,0)[12], AIC=1370.81
(7) ARIMA(0,0,12)(0,1,0)[12], AIC=1370.92
(8) ARIMA(0,0,12)(0,1,0)[12], AIC=1370.92
(9) ARIMA(15,0,0)(0,1,4)[12], AIC=1371.49
(10) ARIMA(3,0,12)(0,1,0)[12], AIC=1372.25
(11) ARIMA(0,0,16)(0,1,0)[12], AIC=1372.52
(12) ARIMA(1,0,15)(0,1,0)[12], AIC=1372.60
(13) ARIMA(1,0,12)(0,1,0)[12], AIC=1372.69
(14) ARIMA(0,0,13)(0,1,0)[12], AIC=1372.78
(15) ARIMA(0,0,12)(1,1,0)[12], AIC=1372.79
```

Listing 4: donde $p = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$.

Se puede observar un valle en el mejor ARIMA que tenemos, $\text{ARIMA}(12,0,0)(0,1,4)[12]$, $\text{AIC}=1367.04$, se compararon con sus 4 puntos mas cercanos para confirmar que este punto puede ser visto como un mínimo, en cuanto a AIC se refiere.

Se fijan los valores de $\text{ARIMA}(0,0,0) \times (P,1,Q,12)$ donde $P = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$.

AIC para diferentes combinaciones de $\text{ARIMA}(0,0,0) \times (P,1,Q,12)$




Figura 19: *Elaboración Propia*. AIC donde $P = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$.

```
(1) ARIMA(0,0,0)(0,1,3)[12] AIC=1443.50
(2) ARIMA(0,0,0)(0,1,1)[12] AIC=1443.59
(3) ARIMA(0,0,0)(2,1,1)[12] AIC=1444.11
(4) ARIMA(0,0,0)(1,1,2)[12] AIC=1445.15
(5) ARIMA(0,0,0)(1,1,3)[12] AIC=1445.28
(6) ARIMA(0,0,0)(0,1,4)[12] AIC=1445.49
(7) ARIMA(0,0,0)(0,1,2)[12] AIC=1445.59
(8) ARIMA(0,0,0)(1,1,1)[12] AIC=1445.59
(9) ARIMA(0,0,0)(4,1,3)[12] AIC=1445.70
(10) ARIMA(0,0,0)(4,1,4)[12] AIC=1445.74
(11) ARIMA(0,0,0)(2,1,2)[12] AIC=1445.92
(12) ARIMA(0,0,0)(4,1,2)[12] AIC=1445.95
(13) ARIMA(0,0,0)(3,1,1)[12] AIC=1446.07
(14) ARIMA(0,0,0)(2,1,3)[12] AIC=1446.38
(15) ARIMA(0,0,0)(1,1,4)[12] AIC=1446.57
(16) ARIMA(0,0,0)(4,1,1)[12] AIC=1446.70
(17) ARIMA(0,0,0)(3,1,2)[12] AIC=1446.99
```

Listing 5: Modelos Ordenados por AIC donde $P = 0, 1, 2, \dots$ y $Q = 0, 1, 2, \dots$.

Se puede observar que cuando se varía P y Q , mientras se mantienen fijos $p = q = 0$, se obtienen los modelos con menor AIC, mostrando la importancia de incluir partes no estacionales en el modelo.

A continuación se muestran los resultados completos:

```
(1) ARIMA(12,0,0) (0,1,4) [12], AIC=1367.04
(2) ARIMA(13,0,0) (0,1,4) [12], AIC=1367.37
(3) ARIMA(12,0,0) (0,1,3) [12], AIC=1368.24
(4) ARIMA(12,0,0) (0,1,5) [12], AIC=1369.25
(5) ARIMA(0,0,15) (0,1,0) [12], AIC=1370.81
(6) ARIMA(0,0,15) (0,1,0) [12], AIC=1370.81
(7) ARIMA(0,0,12) (0,1,0) [12], AIC=1370.92
(8) ARIMA(0,0,12) (0,1,0) [12], AIC=1370.92
(9) ARIMA(15,0,0) (0,1,4) [12], AIC=1371.49
(10) ARIMA(3,0,12) (0,1,0) [12], AIC=1372.25
(11) ARIMA(0,0,16) (0,1,0) [12], AIC=1372.52
(12) ARIMA(1,0,15) (0,1,0) [12], AIC=1372.60
(13) ARIMA(1,0,12) (0,1,0) [12], AIC=1372.69
(14) ARIMA(0,0,13) (0,1,0) [12], AIC=1372.78
(15) ARIMA(0,0,12) (1,1,0) [12], AIC=1372.79
(16) ARIMA(3,0,13) (0,1,0) [12], AIC=1372.87
(17) ARIMA(0,0,15) (1,1,0) [12], AIC=1373.17
(18) ARIMA(0,0,12) (2,1,0) [12], AIC=1373.37
(19) ARIMA(4,0,12) (0,1,0) [12], AIC=1373.41
(20) ARIMA(1,0,16) (0,1,0) [12], AIC=1373.59
(21) ARIMA(1,0,13) (0,1,0) [12], AIC=1373.76
(22) ARIMA(0,0,13) (1,1,0) [12], AIC=1373.86
(23) ARIMA(3,0,14) (0,1,0) [12], AIC=1374.01
(24) ARIMA(4,0,13) (0,1,0) [12], AIC=1374.12
(25) ARIMA(5,0,12) (0,1,0) [12], AIC=1374.34
(26) ARIMA(0,0,14) (0,1,0) [12], AIC=1374.44
(27) ARIMA(2,0,12) (0,1,0) [12], AIC=1374.49
(28) ARIMA(2,0,12) (0,1,0) [12], AIC=1374.49
(29) ARIMA(0,0,17) (0,1,0) [12], AIC=1374.49
(30) ARIMA(2,0,15) (0,1,0) [12], AIC=1374.62
(31) ARIMA(2,0,15) (0,1,0) [12], AIC=1374.62
(32) ARIMA(1,0,17) (0,1,0) [12], AIC=1374.97
(33) ARIMA(4,0,14) (0,1,0) [12], AIC=1375.08
(34) ARIMA(2,0,13) (0,1,0) [12], AIC=1375.16
(35) ARIMA(2,0,13) (0,1,0) [12], AIC=1375.16
(36) ARIMA(1,0,14) (0,1,0) [12], AIC=1375.26
(37) ARIMA(5,0,13) (0,1,0) [12], AIC=1375.43
(38) ARIMA(0,0,12) (4,1,0) [12], AIC=1375.93
(39) ARIMA(6,0,12) (0,1,0) [12], AIC=1375.94
(40) ARIMA(6,0,12) (0,1,0) [12], AIC=1375.94
(41) ARIMA(2,0,16) (0,1,0) [12], AIC=1375.97
(42) ARIMA(2,0,16) (0,1,0) [12], AIC=1375.97
(43) ARIMA(3,0,15) (0,1,0) [12], AIC=1376.37
(44) ARIMA(7,0,12) (0,1,0) [12], AIC=1376.46
(45) ARIMA(2,0,14) (0,1,0) [12], AIC=1376.63
(46) ARIMA(2,0,14) (0,1,0) [12], AIC=1376.63
(47) ARIMA(5,0,14) (0,1,0) [12], AIC=1377.04
(48) ARIMA(0,0,14) (2,1,0) [12], AIC=1377.49
(49) ARIMA(6,0,13) (0,1,0) [12], AIC=1377.52
(50) ARIMA(6,0,13) (0,1,0) [12], AIC=1377.52
(51) ARIMA(4,0,15) (0,1,0) [12], AIC=1377.61
(52) ARIMA(2,0,17) (0,1,0) [12], AIC=1377.67
(53) ARIMA(2,0,17) (0,1,0) [12], AIC=1377.67
(54) ARIMA(3,0,16) (0,1,0) [12], AIC=1377.71
(55) ARIMA(7,0,13) (0,1,0) [12], AIC=1378.15
(56) ARIMA(8,0,12) (0,1,0) [12], AIC=1378.47
(57) ARIMA(8,0,12) (0,1,0) [12], AIC=1378.47
(58) ARIMA(9,0,12) (0,1,0) [12], AIC=1378.79
(59) ARIMA(6,0,14) (0,1,0) [12], AIC=1378.97
(60) ARIMA(6,0,14) (0,1,0) [12], AIC=1378.97
(61) ARIMA(4,0,16) (0,1,0) [12], AIC=1379.46
(62) ARIMA(3,0,17) (0,1,0) [12], AIC=1379.51
(63) ARIMA(5,0,15) (0,1,0) [12], AIC=1379.68
(64) ARIMA(8,0,13) (0,1,0) [12], AIC=1380.15
(65) ARIMA(8,0,13) (0,1,0) [12], AIC=1380.15
(66) ARIMA(7,0,14) (0,1,0) [12], AIC=1380.53
(67) ARIMA(10,0,12) (0,1,0) [12], AIC=1380.62
(68) ARIMA(5,0,16) (0,1,0) [12], AIC=1380.90
(69) ARIMA(4,0,17) (0,1,0) [12], AIC=1381.04
(70) ARIMA(6,0,15) (0,1,0) [12], AIC=1381.49
(71) ARIMA(6,0,15) (0,1,0) [12], AIC=1381.49
(72) ARIMA(10,0,13) (0,1,0) [12], AIC=1381.66
```

```

(73) ARIMA(9,0,13)(0,1,0)[12], AIC=1381.75
(74) ARIMA(8,0,14)(0,1,0)[12], AIC=1382.31
(75) ARIMA(8,0,14)(0,1,0)[12], AIC=1382.31
(76) ARIMA(5,0,17)(0,1,0)[12], AIC=1382.35
(77) ARIMA(11,0,12)(0,1,0)[12], AIC=1382.48
(78) ARIMA(9,0,14)(0,1,0)[12], AIC=1382.58
(79) ARIMA(6,0,16)(0,1,0)[12], AIC=1382.64
(80) ARIMA(6,0,16)(0,1,0)[12], AIC=1382.64
(81) ARIMA(12,0,0)(0,1,1)[12], AIC=1382.66
(82) ARIMA(7,0,15)(0,1,0)[12], AIC=1382.73
(83) ARIMA(10,0,14)(0,1,0)[12], AIC=1383.53
(84) ARIMA(11,0,13)(0,1,0)[12], AIC=1383.82
(85) ARIMA(6,0,17)(0,1,0)[12], AIC=1384.31
(86) ARIMA(6,0,17)(0,1,0)[12], AIC=1384.31
(87) ARIMA(7,0,16)(0,1,0)[12], AIC=1384.33
(88) ARIMA(8,0,15)(0,1,0)[12], AIC=1384.52
(89) ARIMA(8,0,15)(0,1,0)[12], AIC=1384.52
(90) ARIMA(9,0,15)(0,1,0)[12], AIC=1384.53
(91) ARIMA(13,0,12)(0,1,0)[12], AIC=1384.56
(92) ARIMA(11,0,14)(0,1,0)[12], AIC=1384.73
(93) ARIMA(13,0,13)(0,1,0)[12], AIC=1385.12
(94) ARIMA(10,0,15)(0,1,0)[12], AIC=1385.45
(95) ARIMA(12,0,13)(0,1,0)[12], AIC=1385.52
(96) ARIMA(8,0,16)(0,1,0)[12], AIC=1385.88
(97) ARIMA(8,0,16)(0,1,0)[12], AIC=1385.88
(98) ARIMA(12,0,12)(0,1,0)[12], AIC=1386.15
(99) ARIMA(7,0,17)(0,1,0)[12], AIC=1386.37
(100) ARIMA(11,0,15)(0,1,0)[12], AIC=1386.42
(101) ARIMA(9,0,16)(0,1,0)[12], AIC=1386.43
(102) ARIMA(13,0,14)(0,1,0)[12], AIC=1386.89
(103) ARIMA(12,0,14)(0,1,0)[12], AIC=1386.90
(104) ARIMA(10,0,16)(0,1,0)[12], AIC=1387.11
(105) ARIMA(14,0,13)(0,1,0)[12], AIC=1387.36
(106) ARIMA(15,0,0)(0,1,1)[12], AIC=1387.68
(107) ARIMA(14,0,12)(0,1,0)[12], AIC=1387.85
(108) ARIMA(11,0,16)(0,1,0)[12], AIC=1387.97
(109) ARIMA(8,0,17)(0,1,0)[12], AIC=1388.02
(110) ARIMA(8,0,17)(0,1,0)[12], AIC=1388.02
(111) ARIMA(15,0,12)(0,1,0)[12], AIC=1388.42
(112) ARIMA(13,0,15)(0,1,0)[12], AIC=1388.76
(113) ARIMA(12,0,15)(0,1,0)[12], AIC=1388.84
(114) ARIMA(14,0,14)(0,1,0)[12], AIC=1388.89
(115) ARIMA(9,0,17)(0,1,0)[12], AIC=1388.95
(116) ARIMA(10,0,17)(0,1,0)[12], AIC=1389.04
(117) ARIMA(15,0,13)(0,1,0)[12], AIC=1389.30
(118) ARIMA(17,0,12)(0,1,0)[12], AIC=1389.57
(119) ARIMA(11,0,17)(0,1,0)[12], AIC=1389.72
(120) ARIMA(16,0,12)(0,1,0)[12], AIC=1389.87
(121) ARIMA(12,0,16)(0,1,0)[12], AIC=1390.33
(122) ARIMA(15,0,14)(0,1,0)[12], AIC=1390.73
(123) ARIMA(14,0,15)(0,1,0)[12], AIC=1390.78
(124) ARIMA(17,0,13)(0,1,0)[12], AIC=1390.81
(125) ARIMA(16,0,13)(0,1,0)[12], AIC=1390.83
(126) ARIMA(6,0,0)(0,1,1)[12], AIC=1391.61
(127) ARIMA(13,0,16)(0,1,0)[12], AIC=1391.95
(128) ARIMA(12,0,17)(0,1,0)[12], AIC=1392.26
(129) ARIMA(13,0,17)(0,1,0)[12], AIC=1392.28
(130) ARIMA(17,0,14)(0,1,0)[12], AIC=1392.49
(131) ARIMA(11,0,0)(0,1,4)[12], AIC=1392.63
(132) ARIMA(16,0,14)(0,1,0)[12], AIC=1392.69
(133) ARIMA(15,0,15)(0,1,0)[12], AIC=1392.85
(134) ARIMA(14,0,16)(0,1,0)[12], AIC=1392.97
(135) ARIMA(16,0,15)(0,1,0)[12], AIC=1394.72
(136) ARIMA(17,0,15)(0,1,0)[12], AIC=1394.84
(137) ARIMA(15,0,16)(0,1,0)[12], AIC=1395.10
(138) ARIMA(14,0,17)(0,1,0)[12], AIC=1395.38
(139) ARIMA(15,0,17)(0,1,0)[12], AIC=1396.22
(140) ARIMA(17,0,16)(0,1,0)[12], AIC=1396.75
(141) ARIMA(16,0,16)(0,1,0)[12], AIC=1397.15
(142) ARIMA(16,0,17)(0,1,0)[12], AIC=1398.28
(143) ARIMA(10,0,0)(0,1,4)[12], AIC=1398.90
(144) ARIMA(17,0,17)(0,1,0)[12], AIC=1399.30
(145) ARIMA(9,0,11)(0,1,0)[12], AIC=1405.22
(146) ARIMA(11,0,10)(0,1,0)[12], AIC=1405.63

```

```

(147) ARIMA(11,0,11)(0,1,0)[12], AIC=1406.36
(148) ARIMA(10,0,11)(0,1,0)[12], AIC=1411.83
(149) ARIMA(14,0,11)(0,1,0)[12], AIC=1413.61
(150) ARIMA(13,0,11)(0,1,0)[12], AIC=1415.15
(151) ARIMA(8,0,11)(0,1,0)[12], AIC=1415.83
(152) ARIMA(8,0,11)(0,1,0)[12], AIC=1415.83
(153) ARIMA(15,0,11)(0,1,0)[12], AIC=1418.52
(154) ARIMA(16,0,11)(0,1,0)[12], AIC=1418.96
(155) ARIMA(12,0,11)(0,1,0)[12], AIC=1419.07
(156) ARIMA(7,0,11)(0,1,0)[12], AIC=1420.16
(157) ARIMA(15,0,10)(0,1,0)[12], AIC=1427.03
(158) ARIMA(0,0,11)(3,1,0)[12], AIC=1427.35
(159) ARIMA(16,0,10)(0,1,0)[12], AIC=1428.10
(160) ARIMA(16,0,10)(0,1,0)[12], AIC=1428.10
(161) ARIMA(14,0,10)(0,1,0)[12], AIC=1429.08
(162) ARIMA(0,0,10)(3,1,0)[12], AIC=1430.51
(163) ARIMA(4,0,11)(0,1,0)[12], AIC=1430.74
(164) ARIMA(3,0,0)(0,1,1)[12], AIC=1431.92
(165) ARIMA(3,0,11)(0,1,0)[12], AIC=1435.07
(166) ARIMA(17,0,10)(0,1,0)[12], AIC=1436.99
(167) ARIMA(12,0,10)(0,1,0)[12], AIC=1437.18
(168) ARIMA(0,0,11)(2,1,0)[12], AIC=1443.12
(169) ARIMA(0,0,0)(0,1,3)[12], AIC=1443.50
(170) ARIMA(0,0,0)(0,1,1)[12], AIC=1443.59
(171) ARIMA(0,0,0)(0,1,1)[12], AIC=1443.59
(172) ARIMA(5,0,11)(0,1,0)[12], AIC=1443.88
(173) ARIMA(0,0,0)(2,1,1)[12], AIC=1444.11
(174) ARIMA(13,0,10)(0,1,0)[12], AIC=1444.13
(175) ARIMA(0,0,0)(1,1,2)[12], AIC=1445.15
(176) ARIMA(0,0,0)(1,1,3)[12], AIC=1445.28
(177) ARIMA(0,0,0)(0,1,4)[12], AIC=1445.49
(178) ARIMA(0,0,0)(0,1,2)[12], AIC=1445.59
(179) ARIMA(0,0,0)(1,1,1)[12], AIC=1445.59
(180) ARIMA(0,0,0)(4,1,3)[12], AIC=1445.70
(181) ARIMA(0,0,0)(4,1,4)[12], AIC=1445.74
(182) ARIMA(0,0,0)(2,1,2)[12], AIC=1445.92
(183) ARIMA(0,0,0)(4,1,2)[12], AIC=1445.95
(184) ARIMA(0,0,0)(3,1,1)[12], AIC=1446.07
(185) ARIMA(0,0,0)(2,1,3)[12], AIC=1446.38
(186) ARIMA(0,0,0)(1,1,4)[12], AIC=1446.57
(187) ARIMA(0,0,0)(4,1,1)[12], AIC=1446.70
(188) ARIMA(0,0,10)(2,1,0)[12], AIC=1446.97
(189) ARIMA(0,0,0)(3,1,2)[12], AIC=1446.99
(190) ARIMA(0,0,0)(3,1,3)[12], AIC=1447.78
(191) ARIMA(0,0,0)(2,1,4)[12], AIC=1447.80
(192) ARIMA(0,0,0)(4,1,0)[12], AIC=1448.24
(193) ARIMA(6,0,11)(0,1,0)[12], AIC=1449.08
(194) ARIMA(6,0,11)(0,1,0)[12], AIC=1449.08
(195) ARIMA(0,0,0)(3,1,4)[12], AIC=1449.21
(196) ARIMA(16,0,9)(0,1,0)[12], AIC=1450.39
(197) ARIMA(17,0,9)(0,1,0)[12], AIC=1450.46
(198) ARIMA(2,0,11)(0,1,0)[12], AIC=1451.97
(199) ARIMA(2,0,11)(0,1,0)[12], AIC=1451.97
(200) ARIMA(0,0,0)(3,1,0)[12], AIC=1454.13
(201) ARIMA(16,0,8)(0,1,0)[12], AIC=1460.41
(202) ARIMA(0,0,0)(2,1,0)[12], AIC=1464.14
(203) ARIMA(17,0,8)(0,1,0)[12], AIC=1464.61
(204) ARIMA(16,0,7)(0,1,0)[12], AIC=1469.14
(205) ARIMA(17,0,7)(0,1,0)[12], AIC=1469.22
(206) ARIMA(17,0,6)(0,1,0)[12], AIC=1471.02
(207) ARIMA(9,0,10)(0,1,0)[12], AIC=1471.14
(208) ARIMA(8,0,10)(0,1,0)[12], AIC=1478.49
(209) ARIMA(8,0,10)(0,1,0)[12], AIC=1478.49
(210) ARIMA(16,0,5)(0,1,0)[12], AIC=1479.55
(211) ARIMA(16,0,6)(0,1,0)[12], AIC=1480.98
(212) ARIMA(10,0,10)(0,1,0)[12], AIC=1495.41
(213) ARIMA(17,0,5)(0,1,0)[12], AIC=1496.61
(214) ARIMA(6,0,10)(0,1,0)[12], AIC=1497.53
(215) ARIMA(6,0,10)(0,1,0)[12], AIC=1497.53
(216) ARIMA(1,0,11)(0,1,0)[12], AIC=1503.08
(217) ARIMA(0,0,11)(1,1,0)[12], AIC=1511.21
(218) ARIMA(0,0,6)(1,1,0)[12], AIC=1514.47
(219) ARIMA(0,0,8)(1,1,0)[12], AIC=1516.15
(220) ARIMA(0,0,10)(1,1,0)[12], AIC=1516.98

```

```

(221) ARIMA(12,0,0)(0,1,0)[12], AIC=1522.91
(222) ARIMA(0,0,0)(1,1,0)[12], AIC=1526.64
(223) ARIMA(5,0,10)(0,1,0)[12], AIC=1526.92
(224) ARIMA(10,0,6)(0,1,0)[12], AIC=1541.36
(225) ARIMA(4,0,10)(0,1,0)[12], AIC=1542.28
(226) ARIMA(7,0,10)(0,1,0)[12], AIC=1546.44
(227) ARIMA(3,0,10)(0,1,0)[12], AIC=1552.06
(228) ARIMA(2,0,10)(0,1,0)[12], AIC=1552.72
(229) ARIMA(2,0,10)(0,1,0)[12], AIC=1552.72
(230) ARIMA(2,0,10)(0,1,0)[12], AIC=1552.72
(231) ARIMA(2,0,9)(0,1,0)[12], AIC=1555.97
(232) ARIMA(2,0,8)(0,1,0)[12], AIC=1559.09
(233) ARIMA(1,0,8)(0,1,0)[12], AIC=1593.01
(234) ARIMA(0,0,11)(0,1,0)[12], AIC=1599.58
(235) ARIMA(2,0,5)(0,1,0)[12], AIC=1601.11
(236) ARIMA(2,0,6)(0,1,0)[12], AIC=1621.74
(237) ARIMA(0,0,9)(0,1,0)[12], AIC=1621.79
(238) ARIMA(0,0,10)(0,1,0)[12], AIC=1622.73
(239) ARIMA(0,0,10)(0,1,0)[12], AIC=1622.73
(240) ARIMA(1,0,9)(0,1,0)[12], AIC=1623.45
(241) ARIMA(1,0,10)(0,1,0)[12], AIC=1624.20
(242) ARIMA(1,0,10)(0,1,0)[12], AIC=1624.20
(243) ARIMA(1,0,5)(0,1,0)[12], AIC=1627.56
(244) ARIMA(1,0,6)(0,1,0)[12], AIC=1630.49
(245) ARIMA(0,0,7)(0,1,0)[12], AIC=1630.59
(246) ARIMA(0,0,8)(0,1,0)[12], AIC=1630.74
(247) ARIMA(1,0,7)(0,1,0)[12], AIC=1631.92
(248) ARIMA(2,0,7)(0,1,0)[12], AIC=1633.08
(249) ARIMA(0,0,6)(0,1,0)[12], AIC=1635.97
(250) ARIMA(6,0,0)(0,1,0)[12], AIC=1650.81
(251) ARIMA(0,0,5)(0,1,0)[12], AIC=1651.91
(252) ARIMA(0,0,0)(0,1,0)[12], AIC=1653.67

```

Listing 6: Modelos Ordenados por AIC

2.6.2 Serie Transformada

No se siguió el mismo proceso que para la serie sin transformar. Esta vez fue por medio de la FAC y la FACP. Por lo que se encuentra en la sección de Modelos Propuestos

2.7 Modelos Propuestos

Luego de identificar los modelos con mejor desempeño según el criterio de información de Akaike (AIC), mediante una estrategia de búsqueda que consistió en fijar dos parámetros y recorrer sistemáticamente los restantes, en esta sección se presentan los modelos seleccionados para su análisis formal.

Para todas las pruebas estadísticas, se utilizará un nivel de significancia de $\alpha = 0,05$, el cual servirá como umbral para decidir la aceptación o el rechazo de las hipótesis nulas correspondientes. La única excepción será la prueba de independencia de los residuos, evaluada mediante el test de Ljung-Box, para la cual se adopta un nivel de significancia menos estricta de $\alpha = 0,01$. Esta elección responde a la dificultad empírica observada para cumplir con dicho supuesto, por lo que se permite un mayor margen, con el fin de no descartar modelos potencialmente válidos.

2.7.1 Primer Modelo para la Serie Sin Transformar

Se propone el modelo con menor AIC.

Cuadro 1: *Elaboración Propia*. Primer Modelo para la Serie Sin Transformar

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX(12, 0, 0) × (0, 1, 4, 12)	Log Likelihood	-666.522
Date:	Sun, 27 Apr 2025	AIC	1367.044
Time:	04:48:12	BIC	1443.100
Sample:	0	HQIC	1396.549
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.1079	0.032	3.338	0.001	0.045	0.171
ar.L2	-0.0271	0.037	-0.738	0.460	-0.099	0.045
ar.L3	0.0504	0.037	1.367	0.172	-0.022	0.123
ar.L4	-0.0689	0.042	-1.634	0.102	-0.152	0.014
ar.L5	-0.1086	0.050	-2.193	0.028	-0.206	-0.012
ar.L6	-0.1103	0.059	-1.872	0.061	-0.226	0.005
ar.L7	-0.0049	0.050	-0.097	0.923	-0.104	0.094
ar.L8	-0.0450	0.043	-1.039	0.299	-0.130	0.040
ar.L9	0.0411	0.035	1.183	0.237	-0.027	0.109
ar.L10	-0.0133	0.033	-0.406	0.685	-0.078	0.051
ar.L11	0.0968	0.036	2.662	0.008	0.026	0.168
ar.L12	0.5442	0.074	7.328	0.000	0.399	0.690
ma.S.L12	-1.3768	0.084	-16.419	0.000	-1.541	-1.212
ma.S.L24	0.3656	0.079	4.639	0.000	0.211	0.520
ma.S.L36	0.1054	0.060	1.756	0.079	-0.012	0.223
ma.S.L48	-0.0790	0.039	-2.042	0.041	-0.155	-0.003
sigma2	0.4378	0.024	18.022	0.000	0.390	0.485

Ljung-Box (L1) (Q):	0.34	Jarque-Bera (JB):	376.73
Prob(Q):	0.56	Prob(JB):	0.00
Heteroskedasticity (H):	0.82	Skew:	0.89
Prob(H) (two-sided):	0.14	Kurtosis:	6.28

Parsimonia

El modelo no cumple con el principio de parsimonia, ya que cuenta con coeficientes que son altamente no significativos, como el ϕ_7 , con un p-valor de 0,923, pero, aunque no pase

el principio de parsimonia, dado que se intentó con otros 16 modelos de ordenes menores y ninguno cumplia la prueba de residuos independientes, se será flexible en cuanto a este principio.

Invertibilidad

El modelo es invertible, ya que las raíces del polinomio característico de la parte de media móvil (MA) tienen módulo mayor que uno, es decir, se encuentran fuera del círculo unitario en el plano complejo. A continuación se presentan los módulos de dichas raíces:

1,0931, 1,0931, 1,0653, 1,0653, 1,0010, 1,0931,
 1,0931, 1,0653, 1,0653, 1,0653, 1,0653, 1,0010,
 1,0010, 1,0653, 1,0653, 1,0653, 1,0653, 1,0010,
 1,0010, 1,0931, 1,0931, 1,0653, 1,0653, 1,0653,
 1,0653, 1,0010, 1,0010, 1,0931, 1,0931, 1,0653,
 1,0653, 1,0653, 1,0653, 1,0010, 1,0010, 1,0931,
 1,0931, 1,0931, 1,0931, 1,0653, 1,0653, 1,0010,
 1,0653, 1,0653, 1,0653, 1,0653, 1,0010, 1,0010

Estacionariedad

El modelo es estacionario, dado que las raíces del polinomio característico de la parte autorregresiva (AR) también tienen módulo mayor que uno, por lo tanto, también se encuentran fuera del círculo unitario. Los módulos correspondientes se muestran a continuación:

1,1158, 1,0720, 1,0720, 1,0585, 1,0585, 1,0496,
 1,0496, 1,0654, 1,0654, 1,0680, 1,0033, 1,0033

Residuos Independientes

Las pruebas de residuos independientes fueron realizadas con Ljung-Box, los resultados se muestran en el Cuadro 2.

El primer retraso tiene un p-valor de 0.002758, debajo del umbral del 0.01, indicando evidencia estadísticamente significativa de autocorrelación no explicada por el modelo, sin embargo, es el único retraso menor a este umbral, a partir del retraso 4, el p-valor comienza a superar el 0.05 y sigue aumentando sucesivamente, lo que sugiere que no hay evidencia significativa de autocorrelación en esos retrasos. Aunque se espera que todos los residuos sean independientes,

	lb_stat	lb_pvalue
16	8.652910	NaN
17	8.961011	0.002758
18	8.987107	0.011181
19	8.989718	0.029428
20	8.991484	0.061313
21	9.423957	0.093303
22	9.683789	0.138616
23	9.688787	0.206906
24	9.696828	0.286953
25	9.696845	0.375580
26	10.397531	0.406336
27	11.023153	0.441326
28	11.211664	0.510871
29	11.644782	0.556964
30	11.647451	0.634592
31	11.649449	0.705346
32	13.569215	0.630772
33	13.606003	0.694769
34	15.609204	0.619800
35	15.631437	0.681709
36	15.889978	0.723426

Cuadro 2: *Elaboración Propia*. Resultados de la prueba de Ljung-Box para los residuos

comparados con otros modelos, los p-valores obtenidos en este modelo son altos, por lo que se seguirá analizando.

Residuos con Media Cero

Se realizó una prueba t para verificar si la media de los residuos es estadísticamente diferente de cero. El estadístico t obtenido fue $-1,6920$, con un p-valor de $0,0911$, y 659 grados de libertad. Dado que el p-valor es mayor que el nivel de significancia, no se rechaza la hipótesis nula. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que la media de los residuos sea distinta de cero.

Residuos con Varianza Constante

Se aplicó la prueba de Breusch-Pagan para evaluar si los residuos presentan varianza constante. El estadístico de la prueba fue $2,4640$ con un p-valor de $0,1165$. Dado que el p-valor es mayor que el nivel de significancia, no se rechaza la hipótesis nula de homoscedasticidad. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que los residuos presenten heterocedasticidad.

Residuos con Distribución Normal

Se realizaron dos pruebas para evaluar si los residuos siguen una distribución normal:

- Jarque-Bera: El estadístico fue 413,9383 con un p-valor de $1,30 \times 10^{-90}$. Como el p-valor es mucho menor que 0,05, se rechaza la hipótesis nula de normalidad según esta prueba.
- Lilliefors: El p-valor fue 0,0010, por lo que también se rechaza la hipótesis nula de normalidad.

Dado que ambas pruebas rechazan la hipótesis nula, se concluye que los residuos no siguen una distribución normal. Sin embargo, se analiza la proporción de residuos que se encuentran dentro de ciertos múltiplos de la desviación estándar. Si los residuos fueran perfectamente normales, se esperaría aproximadamente un 68 % dentro de $\pm 1\sigma$, un 95 % dentro de $\pm 2\sigma$ y un 99.7 % dentro de $\pm 3\sigma$. Los resultados observados son los siguientes:

- 75.00 % de los residuos están dentro de $\pm 1\sigma$ (esperado = 68 %),
- 93.79 % dentro de $\pm 2\sigma$ (esperado = 95 %),
- 98.79 % dentro de $\pm 3\sigma$ (esperado = 99.7 %).

Gráfico de los Residuos




Figura 21: *Elaboración Propia*. Gráfico de los Residuos del Primer Modelo

También se puede observar que los residuos tienen colas más pesadas que una distribución normal, lo bueno es claramente no hay correlación significativa entre ellos.

2.7.2 Segundo Modelo para la Serie Sin Transformar

Se propone el siguiente modelo encontrado con menor AIC.

Cuadro 3: *Elaboración Propia.* Segundo Modelo para la Serie Sin Transformar

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX(13, 0, 0) × (0, 1, [1, 2, 3, 4], 12)	Log Likelihood	-665.685
Date:	Sun, 27 Apr 2025	AIC	1367.369
Time:	04:49:22	BIC	1447.899
Sample:	0	HQIC	1398.609
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.1369	0.035	3.963	0.000	0.069	0.205
ar.L2	-0.0190	0.036	-0.522	0.602	-0.090	0.052
ar.L3	0.0501	0.037	1.363	0.173	-0.022	0.122
ar.L4	-0.0697	0.042	-1.662	0.097	-0.152	0.013
ar.L5	-0.1117	0.050	-2.254	0.024	-0.209	-0.015
ar.L6	-0.1101	0.060	-1.839	0.066	-0.227	0.007
ar.L7	-0.0104	0.051	-0.205	0.838	-0.110	0.089
ar.L8	-0.0511	0.044	-1.170	0.242	-0.137	0.034
ar.L9	0.0331	0.035	0.944	0.345	-0.036	0.102
ar.L10	-0.0093	0.033	-0.281	0.778	-0.074	0.055
ar.L11	0.1034	0.037	2.802	0.005	0.031	0.176
ar.L12	0.5385	0.080	6.699	0.000	0.381	0.696
ar.L13	-0.0460	0.041	-1.115	0.265	-0.127	0.035
ma.S.L12	-1.3756	0.100	-13.725	0.000	-1.572	-1.179
ma.S.L24	0.3674	0.086	4.275	0.000	0.199	0.536
ma.S.L36	0.0973	0.060	1.635	0.102	-0.019	0.214
ma.S.L48	-0.0784	0.039	-1.994	0.046	-0.155	-0.001
sigma2	0.4340	0.030	14.503	0.000	0.375	0.493

Ljung-Box (L1) (Q):	0.04	Jarque-Bera (JB):	347.08
Prob(Q):	0.85	Prob(JB):	0.00
Heteroskedasticity (H):	0.83	Skew:	0.87
Prob(H) (two-sided):	0.17	Kurtosis:	6.14

Parsimonia

Este modelo tampoco cumple el principio de parsimonia, ya que tiene coeficientes con un p-valor de 0.838 o 0.778, lo que sugiere que el coeficiente no es significativamente distinto de cero. Esto implica que la variable asociada no aporta evidencia suficiente de tener un efecto real en la variable dependiente, y su inclusión en el modelo podría considerarse innecesaria, ya que incrementa su complejidad sin una mejora proporcional en el ajuste o la capacidad predictiva.

Invertibilidad

El modelo es invertible, ya que las raíces del polinomio característico de la parte de media móvil se encuentran fuera del círculo unitario. A continuación se presentan los módulos de

dichas raíces:

1,0935, 1,0935, 1,0626, 1,0626, 1,0014, 1,0935,
 1,0935, 1,0626, 1,0626, 1,0626, 1,0626, 1,0014,
 1,0014, 1,0626, 1,0626, 1,0626, 1,0626, 1,0014,
 1,0014, 1,0935, 1,0935, 1,0626, 1,0626, 1,0626,
 1,0626, 1,0014, 1,0014, 1,0935, 1,0935, 1,0626,
 1,0626, 1,0626, 1,0626, 1,0014, 1,0014, 1,0935,
 1,0935, 1,0935, 1,0935, 1,0626, 1,0626, 1,0014,
 1,0626, 1,0626, 1,0626, 1,0626, 1,0014, 1,0014

Estacionariedad

El modelo es estacionario, ya que las raíces del polinomio característico de la parte autorregresiva también se ubican fuera del círculo unitario. Los módulos correspondientes son los siguientes:

11,8885, 1,0996, 1,0624, 1,0624, 1,0510, 1,0510,
 1,0476, 1,0476, 1,0636, 1,0636, 1,0675, 1,0030,
 1,0030

Residuos Independientes

Se realizó la prueba de Ljung-Box para determinar si hay dependencia en los residuos, los resultados se muestran en el Cuadro 4.

El primer retraso tiene un p-valor de 0.009200, que está por debajo del umbral de 0.01 por 0.001. Esto indica evidencia estadísticamente significativa de autocorrelación no explicada por el modelo. El siguiente retraso, presenta un p-valor de 0.033592, que es mayor al del caso pasado, y, a partir del retraso 3, los p-valores comienzan a superar el 0.05 y continúan aumentando sucesivamente. Estos p-valores son relativamente altos, incluso mas altos que el modelo anterior, lo que sugiere un ajuste aceptable del modelo a partir de ese punto.

Residuos con Media Cero

Se realizó una prueba t para verificar si la media de los residuos es estadísticamente diferente de cero. El estadístico t obtenido fue $-1,6519$, con un p-valor de 0,0990, y 659 grados de libertad. Dado que el p-valor es mayor que el nivel de significancia, no se rechaza la hipótesis nula. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que la media de los residuos sea distinta de cero.

Index	lb_stat	lb_pvalue
17	6.774386	NaN
18	6.783618	0.009200
19	6.786944	0.033592
20	6.809256	0.078232
21	7.196463	0.125863
22	7.428032	0.190703
23	7.441854	0.281909
24	7.447962	0.383773
25	7.506681	0.483077
26	8.263074	0.507868
27	8.898238	0.541788
28	9.010612	0.620913
29	9.533962	0.656772
30	9.544856	0.730662
31	9.545139	0.794626
32	11.177851	0.739888
33	11.194537	0.797321
34	13.243411	0.719745
35	13.251323	0.776431
36	13.698894	0.800953
37	13.804935	0.840247

Cuadro 4: *Elaboración Propia*. Resultados de la prueba de Ljung-Box para los residuos

Residuos con Varianza Constante

Se aplicó la prueba de Breusch-Pagan para evaluar si los residuos presentan varianza constante. El estadístico de la prueba fue 2,2724 con un p-valor de 0,1317. Dado que el p-valor es mayor que el nivel de significancia, no se rechaza la hipótesis nula de homoscedasticidad. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que los residuos presenten heterocedasticidad.

Residuos con Distribución Normal

Se realizaron dos pruebas para evaluar si los residuos siguen una distribución normal:

- Jarque-Bera: El estadístico fue 380,3671 con un p-valor de $2,54 \times 10^{-83}$. Como el p-valor es mucho menor que 0,05, se rechaza la hipótesis nula de normalidad según esta prueba.
- Lilliefors: El p-valor fue 0,0010, por lo que también se rechaza la hipótesis nula de normalidad.

Dado que ambas pruebas rechazan la hipótesis nula, se concluye que los residuos no siguen una distribución normal. Sin embargo, se analiza la proporción de residuos que se encuentran dentro de ciertos múltiplos de la desviación estándar. Si los residuos fueran perfectamente normales, se esperaría aproximadamente un 68 % dentro de $\pm 1\sigma$, un 95 % dentro de $\pm 2\sigma$ y

un 99.7 % dentro de $\pm 3\sigma$. Los resultados observados son los siguientes:

- 75.15 % de los residuos están dentro de $\pm 1\sigma$ (esperado = 68 %),
- 93.79 % dentro de $\pm 2\sigma$ (esperado = 95 %),
- 98.94 % dentro de $\pm 3\sigma$ (esperado = 99.7 %).

Estos resultados sugieren que los residuos presentan un comportamiento aproximadamente normal.

Gráfico de los Residuos

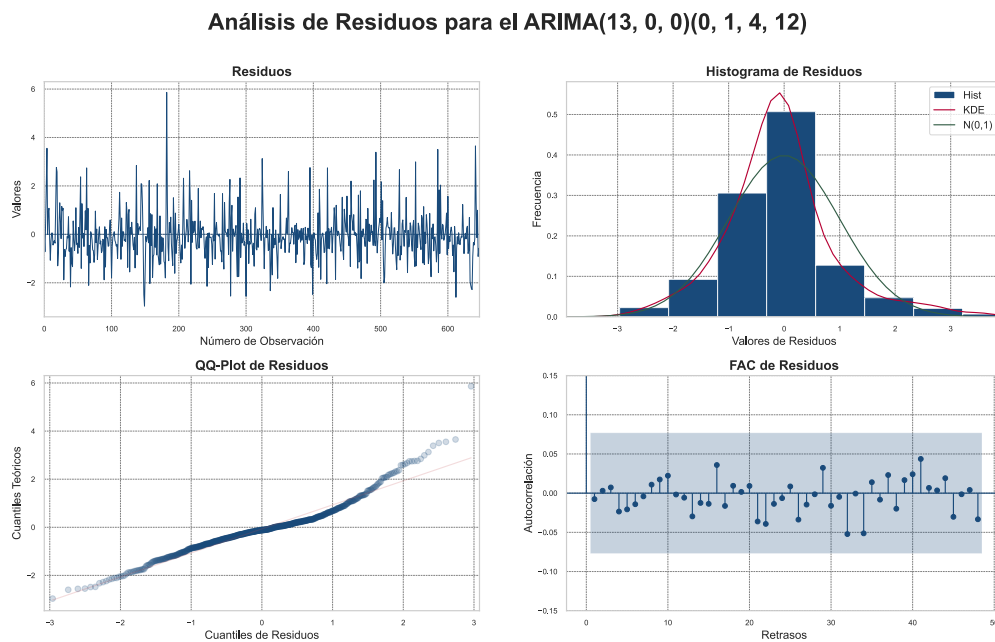


Figura 22: *Elaboración Propia.* Grafico de los Residuos del Primer Modelo

Ocurre lo mismo que en el caso pasado, los residuos tienen colas más pesadas.

2.7.3 Tercer Modelo para la Serie Sin Transformar

Tercer modelo encontrado con menor AIC.

Cuadro 5: *Elaboración Propia*. Tercer Modelo para la Serie Sin Transformar

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX(12, 0, 0) × (0, 1, [1, 2], 12)	Log Likelihood	-668.499
Date:	Sun, 27 Apr 2025	AIC	1366.998
Time:	04:49:32	BIC	1434.107
Sample:	0	HQIC	1393.032
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.1241	0.033	3.797	0.000	0.060	0.188
ar.L2	-0.0278	0.037	-0.746	0.455	-0.101	0.045
ar.L3	0.0593	0.036	1.629	0.103	-0.012	0.131
ar.L4	-0.0777	0.043	-1.819	0.069	-0.161	0.006
ar.L5	-0.1077	0.050	-2.137	0.033	-0.206	-0.009
ar.L6	-0.1154	0.060	-1.914	0.056	-0.234	0.003
ar.L7	-0.0107	0.050	-0.214	0.831	-0.108	0.087
ar.L8	-0.0498	0.044	-1.129	0.259	-0.136	0.037
ar.L9	0.0450	0.036	1.263	0.207	-0.025	0.115
ar.L10	-0.0087	0.033	-0.263	0.793	-0.074	0.056
ar.L11	0.1075	0.035	3.042	0.002	0.038	0.177
ar.L12	0.5090	0.073	6.931	0.000	0.365	0.653
ma.S.L12	-1.3374	0.082	-16.355	0.000	-1.498	-1.177
ma.S.L24	0.3550	0.075	4.760	0.000	0.209	0.501
sigma2	0.4394	0.022	20.157	0.000	0.397	0.482

Ljung-Box (L1) (Q):	0.11	Jarque-Bera (JB):	385.54
Prob(Q):	0.74	Prob(JB):	0.00
Heteroskedasticity (H):	0.82	Skew:	0.91
Prob(H) (two-sided):	0.15	Kurtosis:	6.31

Parsimonia

Este modelo tampoco cumple el principio de parsimonia, ya que tiene coeficientes con un p-valor de 0.793. Cabe mencionar que se intentó eliminarlos, pero al hacerlo los modelos resultantes eran completamente diferentes.

Invertibilidad

El modelo es invertible, ya que las raíces del polinomio característico de la parte de media móvil se encuentran fuera del círculo unitario. A continuación se presentan los módulos de dichas raíces:

1,0876, 1,0023, 1,0876, 1,0876, 1,0023, 1,0023,
1,0876, 1,0876, 1,0023, 1,0023, 1,0876, 1,0876,
1,0023, 1,0023, 1,0876, 1,0876, 1,0023, 1,0023,
1,0876, 1,0876, 1,0876, 1,0023, 1,0023, 1,0023

Estacionariedad

El modelo es estacionario, ya que las raíces del polinomio característico de la parte autorregresiva también se ubican fuera del círculo unitario. Los módulos correspondientes son los siguientes:

1,1241, 1,0745, 1,0745, 1,0577, 1,0577, 1,0535,
1,0535, 1,0679, 1,0679, 1,0635, 1,0026, 1,0026

Residuos Independientes

Se realizó la prueba de Ljung-Box para determinar si hay dependencia en los residuos, los resultados se muestran en el Cuadro 6.

	lb_stat	lb_pvalue
14	8.223545	NaN
15	8.469831	0.003611
16	8.751457	0.012579
17	9.104454	0.027934
18	9.135493	0.057801
19	9.135514	0.103780
20	9.139624	0.165877
21	9.745116	0.203483
22	10.168911	0.253370
23	10.181542	0.335989
24	10.580242	0.391141
25	10.587480	0.478441
26	11.470408	0.489092
27	12.051651	0.523413
28	12.201265	0.590143
29	12.738996	0.622450
30	12.744188	0.691362
31	12.749628	0.752779
32	14.953637	0.665148
33	14.972683	0.724332
34	17.346330	0.630384

Cuadro 6: *Elaboración Propia*. Resultados de la prueba de Ljung-Box para los residuos

El primer retraso muestra un p-valor de 0.003611, claramente por debajo del umbral de 0.01, lo que indica evidencia estadísticamente significativa de autocorrelación no explicada por el modelo. En los siguientes retrasos, los p-valores son parecidos a los otros dos modelos propuestos.

Residuos con Media Cero

Se realizó una prueba t para verificar si la media de los residuos es estadísticamente diferente de cero. El estadístico t obtenido fue $-1,4907$, con un p-valor de 0,1365, y 659 grados de libertad. Dado que el p-valor es mayor que el nivel de significancia, no se rechaza la hipótesis nula. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que la media de los residuos sea distinta de cero.

Residuos con Varianza Constante

Se aplicó la prueba de Breusch-Pagan para evaluar si los residuos presentan varianza constante. El estadístico de la prueba fue 2,3478 con un p-valor de 0,1255. Dado que el p-valor es mayor que el nivel de significancia, no se rechaza la hipótesis nula de homoscedasticidad. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que los residuos presenten heterocedasticidad.

Residuos con Distribución Normal

Se realizaron dos pruebas para evaluar si los residuos siguen una distribución normal:

- Jarque-Bera: El estadístico fue 421,1651 con un p-valor de $3,51 \times 10^{-92}$. Como el p-valor es mucho menor que 0,05, se rechaza la hipótesis nula de normalidad según esta prueba.
- Lilliefors: El p-valor fue 0,0010, por lo que también se rechaza la hipótesis nula de normalidad.

Dado que ambas pruebas rechazan la hipótesis nula, se concluye que los residuos no siguen una distribución normal. Sin embargo, se analiza la proporción de residuos que se encuentran dentro de ciertos múltiplos de la desviación estándar. Si los residuos fueran perfectamente normales, se esperaría aproximadamente un 68 % dentro de $\pm 1\sigma$, un 95 % dentro de $\pm 2\sigma$ y un 99.7 % dentro de $\pm 3\sigma$. Los resultados observados son los siguientes:

- 75.15 % de los residuos están dentro de $\pm 1\sigma$ (esperado = 68 %),
- 94.09 % dentro de $\pm 2\sigma$ (esperado = 95 %),
- 98.79 % dentro de $\pm 3\sigma$ (esperado = 99.7 %).

Gráfico de los Residuos

Finalmente, se repite el mismo problema, colas pesadas en los residuos.

Análisis de Residuos para el ARIMA(12, 0, 0)(0, 1, 2, 12)

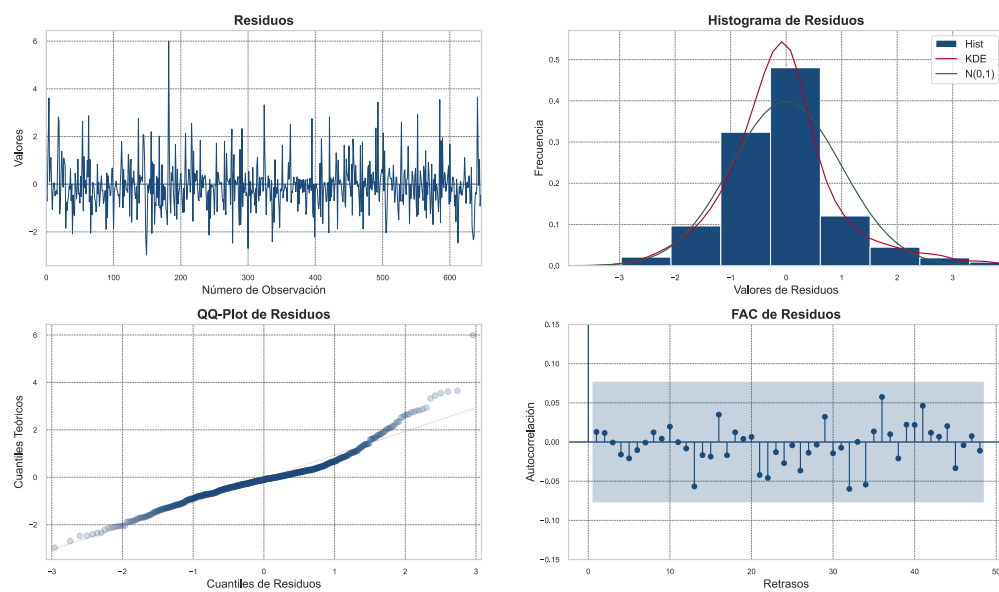


Figura 23: *Elaboración Propia.* Grafico de los Residuos del Tercer Modelo

2.7.4 Cuarto Modelo para la Serie Sin Transformar

Dadas las funciones de autocorrelación simple y parcial, al intentar modelar, fue interesante encontrar este modelo:

Cuadro 7: *Elaboración Propia*. Cuarto Modelo para la Serie Sin Transformar

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX([1, 5], 0, [1, 5]) × (1, 1, 2, 12)	Log Likelihood	-5.099
Date:	Sun, 27 Apr 2025	AIC	26.198
Time:	04:51:06	BIC	61.990
Sample:	0	HQIC	40.083
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	1.1476	32.468	0.035	0.972	-62.489	64.784
ar.L5	-0.8775	38.486	-0.023	0.982	-76.308	74.553
ma.L1	-0.9317	23.880	-0.039	0.969	-47.736	45.872
ma.L5	0.3314	36.742	0.009	0.993	-71.681	72.344
ar.S.L12	-0.3697	133.649	-0.003	0.998	-262.317	261.577
ma.S.L12	-0.1630	41.007	-0.004	0.997	-80.536	80.210
ma.S.L24	-0.7558	42.337	-0.018	0.986	-83.735	82.223
sigma2	0.4434	8.359	0.053	0.958	-15.941	16.827

Ljung-Box (L1) (Q):	294.50	Jarque-Bera (JB):	2,134,861.83
Prob(Q):	0.00	Prob(JB):	0.00
Heteroskedasticity (H):	0.00	Skew:	15.72
Prob(H) (two-sided):	0.00	Kurtosis:	282.43

A pesar de que este modelo presenta el mejor valor de AIC entre todas las especificaciones consideradas, no cumple con ningún supuesto. Todos los parámetros estimados tienen p-valores superiores a 0.95, lo cual sugiere que no son significativamente distintos de cero. Además, los intervalos de confianza son demasiado amplios, lo cual indica una gran inestabilidad en las estimaciones. Esto podría deberse a una fuerte colinealidad entre regresores o a una sobre-especificación del modelo. La media de los residuos es de $-7,786026841214317 \times 10^{48}$, que puede deberse a inestabilidad numérica o un problema de precisión de punto flotante durante el proceso de optimización.

Una posible explicación para que este modelo tenga el menor AIC es que el criterio penaliza la complejidad, pero no exige validez. Esto demuestra la necesidad de no basarse únicamente en criterios de información, y de acompañar siempre la selección de modelos con un análisis de verificación de supuestos y estabilidad numérica.

2.7.5 Primer Modelo Propuesto para la Serie Transformada

Se intentó modelar con la FAC y la FACP, resultando el siguiente modelo:

Cuadro 8: *Elaboración Propia*. Primer Modelo Propuesto para la Serie Transformada

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX([1, 2, 6], 0, 1) × (1, 1, [1, 2, 3, 4, 5, 6], 12)	Log Likelihood	-617.741
Date:	Sun, 27 Apr 2025	AIC	1259.482
Time:	20:29:33	BIC	1313.169
Sample:	0	HQIC	1280.309
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.3566	0.144	2.482	0.013	0.075	0.638
ar.L2	0.0211	0.062	0.342	0.732	-0.100	0.142
ar.L6	-0.2754	0.036	-7.653	0.000	-0.346	-0.205
ma.L1	-0.1092	0.149	-0.731	0.465	-0.402	0.184
ar.S.L12	-0.8536	0.246	-3.468	0.001	-1.336	-0.371
ma.S.L12	0.1009	0.245	0.412	0.680	-0.379	0.581
ma.S.L24	-0.7034	0.191	-3.691	0.000	-1.077	-0.330
ma.S.L36	0.0214	0.049	0.435	0.664	-0.075	0.118
ma.S.L48	0.0154	0.054	0.286	0.775	-0.090	0.121
ma.S.L60	0.0169	0.053	0.319	0.750	-0.087	0.121
ma.S.L72	0.0063	0.055	0.114	0.909	-0.101	0.114
sigma2	0.3874	0.020	19.120	0.000	0.348	0.427

Ljung-Box (L1) (Q):	0.02	Jarque-Bera (JB):	10.86
Prob(Q):	0.88	Prob(JB):	0.00
Heteroskedasticity (H):	0.83	Skew:	-0.20
Prob(H) (two-sided):	0.17	Kurtosis:	3.50

Residuos Independientes

Se realizó la prueba de Ljung-Box para determinar si hay dependencia en los residuos, los resultados se muestran en el Cuadro 9.

Index	lb_stat	lb_pvalue
11	31.550176	NaN
12	31.652621	1.843656e-08
13	31.779184	1.256718e-07
14	31.817201	5.718884e-07
15	31.850384	2.052629e-06
16	34.932704	1.551903e-06
17	42.942269	1.197523e-07
18	48.759895	2.528439e-08
19	50.340543	3.514875e-08
20	50.340543	9.294961e-08

Cuadro 9: *Elaboración Propia*. Resultados de la prueba de Ljung-Box para los residuos

Los resultados presentados muestran una evidencia muy alta de autocorrelación en los residuos del modelo. Desde el retraso uno en adelante, todos los p-valores están muy por debajo del umbral (incluso 0.001). Estos valores indican que hay una fuerte dependencia temporal no capturada, y que los residuos no se comportan como ruido blanco. Por lo que no es necesario más análisis para este modelo, queda descartado.

Análisis de Residuos para el ARIMA(6, 0, 1)(1, 1, 6, 12) con Transformación

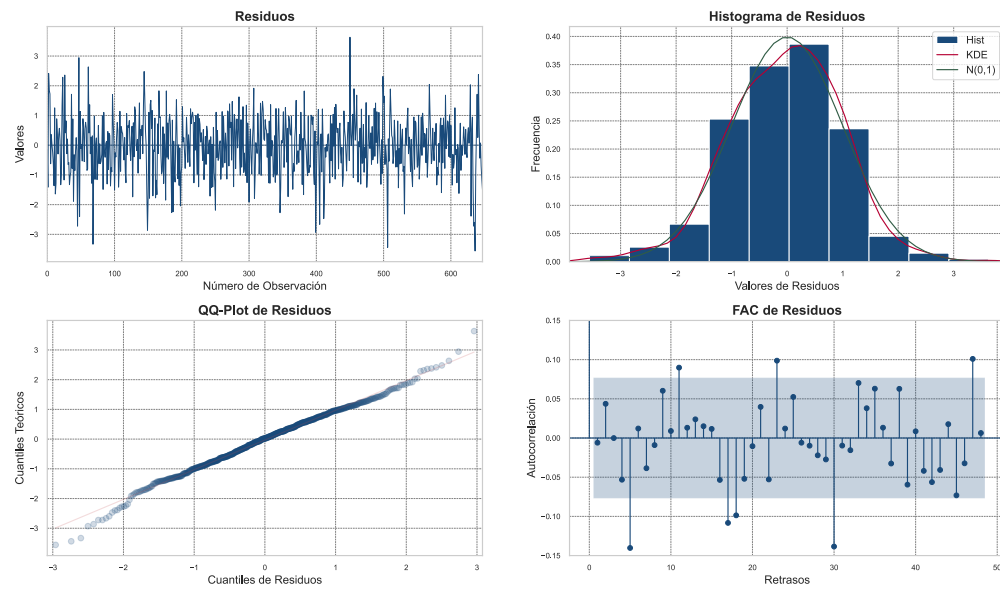


Figura 24: *Elaboración Propia.* Grafico de los Residuos para el Primer Modelo de la Serie Transformada

Por la dependencia en los residuos, cree que faltan parámetros para capturar de una forma más precisa la dependencia temporal de la serie.

2.7.6 Segundo Modelo Propuesto para la Serie Transformada

A este modelo se llegó ajustando el modelo anterior, logrando el AIC menor entre todos los modelos.

Cuadro 10: *Elaboración Propia*. Segundo Modelo Propuesto para la Serie Transformada

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX(6, 0, 0)×(1, 1, [1], 12)	Log Likelihood	-603.289
Date:	Sun, 27 Apr 2025	AIC	1224.578
Time:	20:29:39	BIC	1264.843
Sample:	0	HQIC	1240.198
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.2721	0.034	7.929	0.000	0.205	0.339
ar.L2	0.1022	0.041	2.473	0.013	0.021	0.183
ar.L3	-0.0255	0.040	-0.644	0.520	-0.103	0.052
ar.L4	-0.0900	0.041	-2.215	0.027	-0.170	-0.010
ar.L5	-0.1974	0.039	-5.011	0.000	-0.275	-0.120
ar.L6	-0.2604	0.038	-6.796	0.000	-0.336	-0.185
ar.S.L12	0.0196	0.046	0.426	0.670	-0.071	0.110
ma.S.L12	-0.8851	0.029	-30.327	0.000	-0.942	-0.828
sigma2	0.3670	0.019	19.130	0.000	0.329	0.405

Ljung-Box (L1) (Q):	0.22	Jarque-Bera (JB):	6.43
Prob(Q):	0.64	Prob(JB):	0.04
Heteroskedasticity (H):	0.80	Skew:	-0.19
Prob(H) (two-sided):	0.10	Kurtosis:	3.30

Parsimonia

Aunque este modelo es el que tiene menos coeficientes en comparación a todos los demás, tampoco cumple el principio de parsimonia, teniendo coeficientes con un p-valor de 0.67.

Invertibilidad

El modelo es invertible, ya que las raíces del polinomio característico de la parte de media móvil se encuentran fuera del círculo unitario. A continuación se presentan los módulos de dichas raíces:

1,0102, 1,0102, 1,0102, 1,0102, 1,0102, 1,0102,
1,0102, 1,0102, 1,0102, 1,0102, 1,0102, 1,0102

Estacionariedad

El modelo es estacionario, ya que las raíces del polinomio característico de la parte autorregresiva también se ubican fuera del círculo unitario. Los módulos correspondientes son los siguientes:

1,5325, 1,5648, 1,5648, 1,3008, 1,3008, 1,6452,
1,6452, 1,2588, 1,2588, 1,6720, 1,0589, 1,0589

Residuos Independientes

Se realizó la prueba de Ljung-Box para determinar si hay dependencia en los residuos, los resultados se muestran en el Cuadro 11.

Index	lb_stat	lb_pvalue
9	6.473299	NaN
10	7.880155	0.004998
11	9.034590	0.010919
12	9.198592	0.026764
13	9.646686	0.046819
14	9.995740	0.075356
15	10.036647	0.123117
16	10.813321	0.146972
17	20.147979	0.009790
18	24.051508	0.004221
19	24.928482	0.005483
20	25.176289	0.008590
21	25.707594	0.011804
22	30.300176	0.004262
23	32.585774	0.003304
24	32.718036	0.005134
25	33.218651	0.006912
26	33.280245	0.010384
27	33.486398	0.014565
28	33.781554	0.019498
29	33.785406	0.027614

Cuadro 11: *Elaboración Propia*. Resultados de la prueba de Ljung-Box para los residuos

Es interesante notar que el primer retraso tiene un p-valor de 0.004998 y se incrementa hasta el retraso 7, el p-valor sube a 0.14 y luego de este punto, los p-valores vuelven a caer, en el retraso 12, se muestran retrasos por debajo de 0.01, por ejemplo, 0.009790, lo que indica que la autocorrelación persiste de forma significativa en los retrasos más altos.

Residuos con Media Cero

Se realizó una prueba t para verificar si la media de los residuos es estadísticamente diferente de cero. El estadístico t obtenido fue $-1,3521$, con un p-valor de 0,1768, y 659 grados de libertad. Dado que el p-valor es mayor que el umbral, no se rechaza la hipótesis nula. Por lo tanto, se concluye que no hay evidencia suficiente para afirmar que la media de los residuos sea distinta de cero.

Residuos con Varianza Constante

Se aplicó la prueba de Breusch-Pagan para evaluar si los residuos presentan varianza constante. El estadístico de la prueba fue 8,5927 con un p-valor de 0,0034. Dado que el p-valor

es menor que el umbral, se rechaza la hipótesis nula de homoscedasticidad. Por lo tanto, se concluye que los residuos no presentan varianza constante, es decir, hay evidencia de heteroscedasticidad.

Residuos con Distribución Normal

Se realizaron dos pruebas para evaluar si los residuos siguen una distribución normal:

- Jarque-Bera: El estadístico fue 6,6930 con un p-valor de 0,0352. Siendo muy estrictos, como se fijó un nivel de significancia antes de realizar las pruebas, y el p-valor es menor que 0,05, se rechaza la hipótesis nula de normalidad según esta prueba.
- Lilliefors: El p-valor fue 0,3748, por lo que no se rechaza la hipótesis nula de normalidad.

Dado que las pruebas ofrecen resultados contradictorios, no se puede concluir con certeza que los residuos sigan o no una distribución normal. Sin embargo, la evidencia a favor de la no normalidad no es concluyente. Por lo que se analiza la proporción de residuos que se encuentran dentro de ciertos múltiplos de la desviación estándar. Si los residuos fueran perfectamente normales, se esperaría aproximadamente un 68 % dentro de $\pm 1\sigma$, un 95 % dentro de $\pm 2\sigma$ y un 99.7 % dentro de $\pm 3\sigma$. Los resultados observados son los siguientes:

- 70.00 % de los residuos están dentro de $\pm 1\sigma$ (esperado = 68 %),
- 95.30 % dentro de $\pm 2\sigma$ (esperado = 95 %),
- 99.55 % dentro de $\pm 3\sigma$ (esperado = 99.7 %).

Estos resultados sugieren que los residuos se comportan de manera aproximadamente normal, más que en los otros modelos.

Se puede ver en la figura 25 que, efectivamente, los residuos están altamente correlacionados a partir del retraso 17, pero su distribución de residuos sí podría ser una normal.

Análisis de Residuos para el ARIMA(6, 0, 0)(1, 1, 1, 12) con Transformación

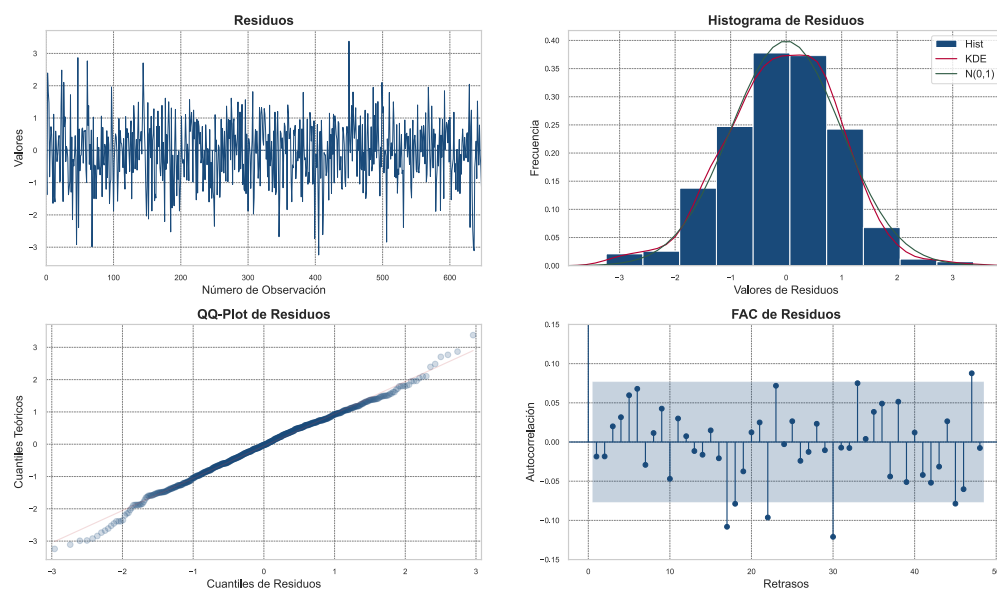


Figura 25: *Elaboración Propia.* Grafico de los Residuos para el Segundo Modelo de la Serie Transformada

2.8 Modelo Seleccionado

Entre los modelos que fueron tratados en la sección anterior, se seleccionó el que se cree tiene la capacidad para modelar mejor la serie de tiempo de la precipitación, que, aunque no cumple el principio de parsimonia, ni pasa el test de normalidad de Jarque Bera ni el de Lilliefors, pero es el que tiene los p-valores del test de Ljung-Box más altos, indicando que es el más capaz de contener la información temporal sobre la serie.

Cuadro 12: *Elaboración Propia*. Modelo Seleccionado para la Serie Sin Transformar

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX(13, 0, 0)×(0, 1, [1, 2, 3, 4], 12)	Log Likelihood	-665.685
Date:	Sun, 27 Apr 2025	AIC	1367.369
Time:	04:49:22	BIC	1447.899
Sample:	0	HQIC	1398.609
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.1369	0.035	3.963	0.000	0.069	0.205
ar.L2	-0.0190	0.036	-0.522	0.602	-0.090	0.052
ar.L3	0.0501	0.037	1.363	0.173	-0.022	0.122
ar.L4	-0.0697	0.042	-1.662	0.097	-0.152	0.013
ar.L5	-0.1117	0.050	-2.254	0.024	-0.209	-0.015
ar.L6	-0.1101	0.060	-1.839	0.066	-0.227	0.007
ar.L7	-0.0104	0.051	-0.205	0.838	-0.110	0.089
ar.L8	-0.0511	0.044	-1.170	0.242	-0.137	0.034
ar.L9	0.0331	0.035	0.944	0.345	-0.036	0.102
ar.L10	-0.0093	0.033	-0.281	0.778	-0.074	0.055
ar.L11	0.1034	0.037	2.802	0.005	0.031	0.176
ar.L12	0.5385	0.080	6.699	0.000	0.381	0.696
ar.L13	-0.0460	0.041	-1.115	0.265	-0.127	0.035
ma.S.L12	-1.3756	0.100	-13.725	0.000	-1.572	-1.179
ma.S.L24	0.3674	0.086	4.275	0.000	0.199	0.536
ma.S.L36	0.0973	0.060	1.635	0.102	-0.019	0.214
ma.S.L48	-0.0784	0.039	-1.994	0.046	-0.155	-0.001
sigma2	0.4340	0.030	14.503	0.000	0.375	0.493

Se comparará con el segundo modelo que fue entrenado con la transformación, dado que sí cumple con el test de Lilliefors y en Jarque Bera tiene un p-valor de 0.03, tiene un menor AIC, pero el único supuesto de los residuos que cumple es normalidad (además del de media cero). Se creó que los intervalos de confianza podrían ser la mayor diferencia entre los modelos (por la normalidad).

Cuadro 13: *Elaboración Propia*. Modelo Seleccionado para la Serie Con Transformaciones

Dep. Variable:	y	No. Observations:	660
Model:	SARIMAX(6, 0, 0)×(1, 1, [1], 12)	Log Likelihood	-603.289
Date:	Sun, 27 Apr 2025	AIC	1224.578
Time:	20:29:39	BIC	1264.843
Sample:	0	HQIC	1240.198
	- 660		
Covariance Type:	opg		

	coef	std err	z	P > z	[0.025	0.975]
ar.L1	0.2721	0.034	7.929	0.000	0.205	0.339
ar.L2	0.1022	0.041	2.473	0.013	0.021	0.183
ar.L3	-0.0255	0.040	-0.644	0.520	-0.103	0.052
ar.L4	-0.0900	0.041	-2.215	0.027	-0.170	-0.010
ar.L5	-0.1974	0.039	-5.011	0.000	-0.275	-0.120
ar.L6	-0.2604	0.038	-6.796	0.000	-0.336	-0.185
ar.S.L12	0.0196	0.046	0.426	0.670	-0.071	0.110
ma.S.L12	-0.8851	0.029	-30.327	0.000	-0.942	-0.828
sigma2	0.3670	0.019	19.130	0.000	0.329	0.405

Es importante recalcar que el modelo principal es el $\text{ARIMA}(13, 0, 0)(0, 1, 4)$, el del modelo de la serie que se entrenó sin transformaciones, y el otro modelo tiene la finalidad de comparar resultados y cuales son las consecuencias de realizar pronósticos cuando se cumplen, o no, ciertos supuestos.

2.9 Pronóstico

En esta sección se compararán los pronósticos del método forecast, que viene con la librería de statsmodels de python, y los pronósticos óptimos realizados con esperanzas condicionales.

2.9.1 Método Forecast

Modelo Obtenido con la Serie Sin Transformar

Obteniendo el pronóstico con el método forecast para los siguientes doce meses, y desestandarizándolos, se obtuvieron los siguientes resultados:

	Pronóstico	Límite Inferior	Límite Superior	Valor Observado	Residuos
2008-12-31	540.502158	-601.447098	1682.451414	74	-466.502158
2009-01-31	201.870616	-951.512847	1355.254079	148	-53.870616
2009-02-28	218.349640	-935.034594	1371.733875	8	-210.349640
2009-03-31	666.919279	-487.716661	1821.555218	64	-602.919279
2009-04-30	824.911936	-331.463983	1981.287855	436	-388.911936
2009-05-31	1406.446553	240.377962	2572.515143	2627	1220.553447
2009-06-30	1256.178392	78.628305	2433.728478	972	-284.178392
2009-07-31	1262.636919	83.406848	2441.866990	1474	211.363081
2009-08-31	1259.408611	77.783466	2441.033756	3161	1901.591389
2009-09-30	736.647934	-445.287230	1918.583099	1190	453.352066
2009-10-31	307.230864	-875.186093	1489.647821	155	-152.230864
2009-11-30	340.113522	-851.828685	1532.055730	51	-289.113522

Cuadro 14: *Elaboración Propia*. Pronósticos, límites y residuos del modelo de la serie sin transformar




Figura 26: *Elaboración Propia*. Método Forecast del Modelo con la Serie Sin Transformar

Se puede notar que el valor de octubre no está en el IC a un 95 %, esto ocurre seguramente porque el modelo no cuenta con una distribución normal en los residuos.

Modelo Obtenido con la Serie Transformada

Obteniendo el pronóstico para los siguientes doce meses con el método forecast, desestandarizándolos y aplicando la transformación inversa de Yeo-Johnson, se obtuvieron los siguientes resultados:

	Pronóstico	Límite Inferior	Límite Superior	Valor Observado	Residuos
2008-12-31	44.953714	-1.768799	634.580471	74	29.046286
2009-01-31	86.154521	-1.056604	965.287325	148	61.845479
2009-02-28	68.232307	-1.477922	872.355113	8	-60.232307
2009-03-31	131.127054	-0.297873	1260.040847	64	-67.127054
2009-04-30	428.426175	15.699218	2617.210481	436	7.573825
2009-05-31	763.114253	47.562078	3972.644947	2627	1863.885747
2009-06-30	779.087074	37.660483	4409.534391	972	192.912926
2009-07-31	869.768181	43.029260	4890.317654	1474	604.231819
2009-08-31	900.651856	44.624350	5062.589225	3161	2260.348144
2009-09-30	485.254867	10.547197	3399.343448	1190	704.745133
2009-10-31	155.744319	-0.807449	1736.882669	155	-0.744319
2009-11-30	108.943275	-1.512804	1460.964464	51	-57.943275

Cuadro 15: *Elaboración Propia*. Pronósticos, límites y residuos de la serie transformada




Figura 27: *Elaboración Propia*. Método Forecast del Modelo con la Serie Transformada

Es interesante notar que en este modelo el intervalo de confianza apenas llega a ser negativo, esto puede ser debido a la normalidad en los residuos, sin embargo, no se esperaba un comportamiento tan "bueno" del IC, ya que se creía que el estimador puntual sería incorrecto.

Comparación entre Ambos Modelos

Se comparan ambos pronósticos, uno del modelo con la serie transformada y otro con el modelo de la serie sin transformar.

	Pronóstico	Pronóstico T	Valor Observado	Residuos	Residuos T
2008-12-31	44.953714	540.502158	74	29.046286	-466.502158
2009-01-31	86.154521	201.870616	148	61.845479	-53.870616
2009-02-28	68.232307	218.349640	8	-60.232307	-210.349640
2009-03-31	131.127054	666.919279	64	-67.127054	-602.919279
2009-04-30	428.426175	824.911936	436	7.573825	-388.911936
2009-05-31	763.114253	1406.446553	2627	1863.885747	1220.553447
2009-06-30	779.087074	1256.178392	972	192.912926	-284.178392
2009-07-31	869.768181	1262.636919	1474	604.231819	211.363081
2009-08-31	900.651856	1259.408611	3161	2260.348144	1901.591389
2009-09-30	485.254867	736.647934	1190	704.745133	453.352066
2009-10-31	155.744319	307.230864	155	-0.744319	-152.230864
2009-11-30	108.943275	340.113522	51	-57.943275	-289.113522

Cuadro 16: *Elaboración Propia.* Comparación entre Modelos




Figura 28: *Elaboración Propia.* Comparación entre Modelos

Se observa que, en cuanto a estimación puntual, el modelo sin transformaciones se encuentra siempre con valores más positivos que el modelo que se entrenó con transformaciones, teniendo residuos más bajos en temporadas con alta precipitación, y el otro al revés.

2.9.2 Pronóstico Óptimo

El pronóstico óptimo se calcula únicamente para el primer modelo.

$$\text{ARIMA}(13, 0, 0) \times (0, 1, 4)_{12} \text{ para } X_t$$

con coeficientes:

$$\begin{array}{lll} \phi_1 = 0,136917, & \phi_2 = 0,019014, & \phi_3 = -0,050067, \\ \phi_4 = 0,069698, & \phi_5 = 0,111714, & \phi_6 = 0,110100, \\ \phi_7 = 0,010426, & \phi_8 = 0,051137, & \phi_9 = -0,033088, \\ \phi_{10} = 0,009268, & \phi_{11} = -0,103359, & \phi_{12} = -0,538506, \\ \phi_{13} = 0,046024, & \Theta_1 = 1,375601, & \Theta_2 = -0,367441, \\ \Theta_3 = -0,097350, & \Theta_4 = 0,078355 & \end{array}$$

Desarrollo para el Pronóstico Óptimo

El modelo puede representarse como:

$$\Phi_0(B^{12})\phi_{13}(B)\nabla_{12}X_t = \Theta_4(B^{12})\varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1)$$

Lado izquierdo:

$$(1 - \phi_1 B - \dots - \phi_{13} B^{13})(X_t - X_{t-12}) = X_t - X_{t-12} - \sum_{h=1}^{13} \phi_h (X_{t-h} - X_{t-h-12})$$

Lado derecho:

$$(1 - \Theta_1 B^{12} - \Theta_2 B^{24} - \Theta_3 B^{36} - \Theta_4 B^{48})\varepsilon_t = \varepsilon_t - \sum_{j=1}^4 \Theta_j \varepsilon_{t-12j}$$

Despejando X_t :

$$X_t = X_{t-12} + \sum_{k=1}^{13} \phi_k (X_{t-k} - X_{t-k-12}) + \varepsilon_t - \sum_{j=1}^4 \Theta_j \varepsilon_{t-12j}$$

Por lo que, el pronóstico óptimo es:

$$X_t(h) = \mathbb{E}_t[X_{t+h-12}] + \sum_{k=1}^{13} \phi_k (\mathbb{E}_t[X_{t+h-k}] - \mathbb{E}_t[X_{t+h-k-12}]) + \mathbb{E}_t[\varepsilon_{t+h}] - \sum_{j=1}^4 \Theta_j \mathbb{E}_t[\varepsilon_{t+h-12j}]$$

Resultados del Pronóstico Óptimo

Una vez sumado el polinomio de 32 términos, se obtienen los siguientes resultados

$$\begin{aligned} X_{672}(1) &= -0,0597 \\ X_{672}(2) &= -0,6402 \\ X_{672}(3) &= -0,3030 \\ X_{672}(4) &= 0,0024 \\ X_{672}(5) &= 0,0789 \\ X_{672}(6) &= 1,2996 \\ X_{672}(7) &= 2,0781 \\ X_{672}(8) &= 1,0283 \\ X_{672}(9) &= 0,3826 \\ X_{672}(10) &= 0,6342 \\ X_{672}(11) &= -0,0721 \\ X_{672}(12) &= -1,1106 \end{aligned}$$

Intervalo de Confianza

Ya que tenemos el pronóstico óptimo (estandarizado) se obtienen los intervalos de confianza.

Dado que $\text{Var}(X_t(h)) = \left(\sum_{j=0}^h \psi_j^2\right) \sigma^2$, los intervalos de confianza al 95 % son:

$$X_t(h) \pm Z_{\frac{\alpha}{2}} \cdot \sqrt{\sum_{j=0}^h \psi_j^2} \cdot \hat{\sigma}_\varepsilon$$

donde los ψ_j se calculan mediante la recursión:

- $\psi_0 = -1$
- $\psi_i = \theta_i + \sum_{k=1}^i \Phi_k \psi_{i-k}$ si $i \leq q$
- $\psi_i = \sum_{k=1}^{p+d} \Phi_k \psi_{i-k}$ si $i > q$

Cálculo de las ψ

Se calculan las ψ

$$\psi_0 = -1$$

$$\psi_1 = -0,14196630827330695$$

$$\psi_2 = -0,0012833831644303538$$

$$\psi_3 = -0,04711945564958303$$

$$\psi_4 = 0,055666495988799594$$

$$\psi_5 = 0,13168502721815675$$

$$\psi_6 = 0,14390060444632985$$

$$\psi_7 = 0,05528005326826947$$

$$\psi_8 = 0,06597563860600197$$

$$\psi_9 = -0,023742200999115167$$

$$\psi_{10} = -0,029931708277211113$$

$$\psi_{11} = -0,13198547391317694$$

$$\psi_{12} = 0,7710272345141591$$

Desviación Estándar del Ruido Blanco

Se obtiene la desviación estándar del ruido blanco, $\sigma = 0,6807672997433546$.

Intervalos de Predicción

Se calculan los intervalos de predicción de la siguiente forma, con $\alpha = 0,95$:

$$X_t(h) \pm Z_{\frac{\alpha}{2}} \cdot \sqrt{\sum_{j=0}^h \psi_j^2 \cdot \hat{\sigma}_\varepsilon}$$

Obteniendo los siguientes resultados:

- Intervalo 1: $(-1,393982459496975, 1,2746253554969749)$
- Intervalo 2: $(-1,9878485554111043, 0,7075172474111042)$
- Intervalo 3: $(-1,6506852053494947, 1,0446827733494948)$
- Intervalo 4: $(-1,3467435497585691, 1,3515559017585692)$
- Intervalo 5: $(-1,2722535341171932, 1,4301320121171934)$
- Intervalo 6: $(-0,06293200205383043, 2,6622066420538304)$
- Intervalo 7: $(0,7020341131440195, 3,45409653885598)$
- Intervalo 8: $(-0,349748182450476, 2,406265238450476)$
- Intervalo 9: $(-0,9982177354298769, 1,7634137014298767)$
- Intervalo 10: $(-0,7469687343170736, 2,0153894083170734)$
- Intervalo 11: $(-1,4538500316205047, 1,3096627116205048)$
- Intervalo 12: $(-2,5035084583313623, 0,2823594183313627)$

Desestandarización

Desestandarizamos con $\mu = 784,0136363636364$, $\sigma = 880,4446163963537$.

si z representa un pronóstico,

$$z = X_t(h) \pm Z_{\frac{\alpha}{2}} \cdot \sqrt{\sum_{j=0}^h \psi_j^2 \cdot \hat{\sigma}_\varepsilon}$$

se desestandariza así:

$$x = z \cdot \sigma + \mu$$

y x representa el valor en la escala original.

Se aplica el mismo procedimiento para el intervalo de confianza.

Resultados

Se obtienen los siguientes resultados del pronóstico óptimo.

	Pronóstico	Límite Inferior	Límite Superior	Valor Observado	Residuos
2008-12-31	731.469977	-443.310715	1906.250669	74	-657.469977
2009-01-31	220.383233	-966.176922	1406.943388	148	-72.383233
2009-02-28	517.237847	-669.323266	1703.798960	8	-509.237847
2009-03-31	786.132141	-401.719472	1973.983754	64	-722.132141
2009-04-30	853.515264	-336.135138	2043.165667	436	-417.515264
2009-05-31	1928.272318	728.605494	3127.939142	2627	698.727682
2009-06-30	2613.635065	1402.115792	3825.154339	972	-1641.635065
2009-07-31	1689.338322	476.079732	2902.596911	1474	-215.338322
2009-08-31	1120.869971	-94.861795	2336.601736	3161	2040.130029
2009-09-30	1342.400713	126.349036	2558.452391	1190	-152.400713
2009-10-31	720.539162	-496.020797	1937.099120	155	-565.539162
2009-11-30	-193.785721	-1420.186908	1032.615466	51	244.785721

Cuadro 17: *Elaboración Propia*. Pronósticos, límites y residuos del cálculo del pronóstico óptimo




Figura 29: *Elaboración Propia*. Pronóstico Óptimo con Esperanzas Condicionales

En la Figura 29 se nota la importancia de que el modelo cumpla el supuesto de normalidad en los residuos, podemos ver que, otra vez, en octubre de 2009 se encuentra una observación que está fuera del intervalo de confianza. Por cómo está definido el modelo, con 13 parámetros autorregresivos, se nota que el pronóstico es demasiado parecido a las observaciones del año anterior, esta vez teniendo el pico de septiembre bajo, debido a que en años anteriores no llovió durante esas fechas.

Comparación

En esta sección se comparan los resultados del método forecast y del pronóstico óptimo.

	Pronóstico Óptimo	Método Forecast	Valor Observado	Residuos Óptimo	Residuos Forecast
2008-12-31	731.469977	540.502158	74	-657.469977	-466.502158
2009-01-31	220.383233	201.870616	148	-72.383233	-53.870616
2009-02-28	517.237847	218.349640	8	-509.237847	-210.349640
2009-03-31	786.132141	666.919279	64	-722.132141	-602.919279
2009-04-30	853.515264	824.911936	436	-417.515264	-388.911936
2009-05-31	1928.272318	1406.446553	2627	698.727682	1220.553447
2009-06-30	2613.635065	1256.178392	972	-1641.635065	-284.178392
2009-07-31	1689.338322	1262.636919	1474	-215.338322	211.363081
2009-08-31	1120.869971	1259.408611	3161	2040.130029	1901.591389
2009-09-30	1342.400713	736.647934	1190	-152.400713	453.352066
2009-10-31	720.539162	307.230864	155	-565.539162	-152.230864
2009-11-30	-193.785721	340.113522	51	244.785721	-289.113522

Cuadro 18: *Elaboración Propia*. Comparación entre el pronóstico óptimo y el método Forecast, junto con sus respectivos residuos

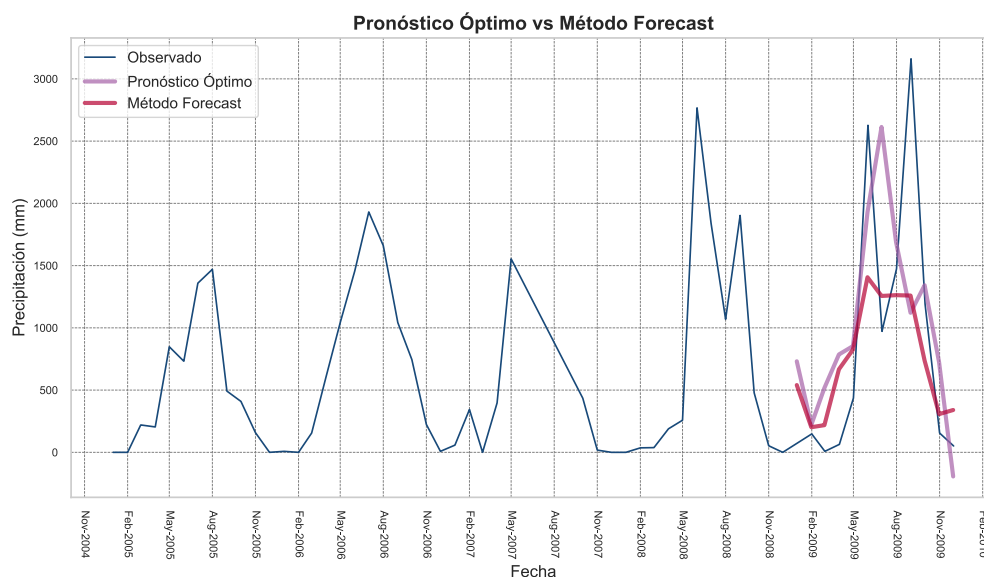


Figura 30: *Elaboración Propia*. Comparación de Pronóstico Óptimo contra Método Forecast

Se puede notar que de ambas maneras se consigue un tipo de pronóstico estacional que tiene sus valores más altos durante el periodo de verano. En el cuadro 18, se puede ver que el método forecast tiene menores residuos a futuro que el método de pronóstico óptimo, indicando un mejor ajuste.

2.10 Actualización de Pronóstico

En esta sección se agrega el valor de diciembre de 2008, 74 estandarizado, y se realiza la actualización de pronóstico con el método forecast y de la manera en que se abordó en clase para luego compararlos.

2.10.1 Método Forecast

En esta sección se realiza la actualización de pronóstico con el método forecast, donde se obtuvieron los siguientes resultados:

	Pronóstico	Pronóstico Actualizado	Valor Observado	Residuos	Residuos Actualizados
2009-01-31	201.870616	135.678753	148	-53.870616	12.321247
2009-02-28	218.349640	217.762493	8	-210.349640	-209.762493
2009-03-31	666.919279	644.960938	64	-602.919279	-580.960938
2009-04-30	824.911936	850.856468	436	-388.911936	-414.856468
2009-05-31	1406.446553	1467.835729	2627	1220.553447	1159.164271
2009-06-30	1256.178392	1323.237743	972	-284.178392	-351.237743
2009-07-31	1262.636919	1288.347469	1474	211.363081	185.652531
2009-08-31	1259.408611	1290.129012	3161	1901.591389	1870.870988
2009-09-30	736.647934	725.578659	1190	453.352066	464.421341
2009-10-31	307.230864	293.280258	155	-152.230864	-138.280258
2009-11-30	340.113522	278.605347	51	-289.113522	-227.605347

Cuadro 19: *Elaboración Propia*. Comparación entre el pronóstico, el pronóstico actualizado, los valores reales y los residuos




Figura 31: *Elaboración Propia*. Actualización del Pronóstico con Método Forecast

Se observa que en general, aunque los cambios sean mínimos, los residuos a futuro son más pequeños una vez que se ha actualizado el pronóstico, pero casi no hay diferencia en la forma de la serie.

2.10.2 Actualización de Pronóstico

En esta sección se muestra la actualización de pronóstico realizada en Excel.

	Pronóstico Óptimo	Pronóstico Actualizado	Valor Observado	Residuos Óptimo	Residuos Actualizado
2008-12-31	731.469977	74.000000	74	-657.469977	0.000000
2009-01-31	220.383233	127.044647	148	-72.383233	20.955353
2009-02-28	517.237847	516.394061	8	509.237847	508.394061
2009-03-31	786.132141	755.152514	64	722.132141	691.152514
2009-04-30	853.515264	890.114314	436	417.515264	454.114314
2009-05-31	1928.272318	2014.851270	2627	-698.727682	-612.148730
2009-06-30	2613.635065	2708.245392	972	1641.635065	1736.245392
2009-07-31	1689.338322	1725.683297	1474	215.338322	251.683297
2009-08-31	1120.869971	1164.246972	3161	-2040.130029	-1996.753028
2009-09-30	1342.400713	1326.790929	1190	152.400713	136.790929
2009-10-31	720.539162	700.859962	155	565.539162	545.859962
2009-11-30	-193.785721	-280.562207	51	-244.785721	-331.562207

Cuadro 20: *Elaboración Propia*. Comparación entre el pronóstico óptimo, el pronóstico actualizado y los residuos correspondientes




Figura 32: *Elaboración Propia*. Actualización del Pronóstico

Ocurre lo mismo que en el caso pasado, una vez actualizado y generando pequeños cambios sin cambiar su forma, el pronóstico los residuos a futuro son menores, excepto en los meses de junio y julio.

2.10.3 Comparación

En esta sección se comparan los resultados obtenidos luego de actualizar el pronóstico con el método forecast y con actualización del pronóstico.

	Pronóstico Actualizado	Método Forecast Actualizado	Valor Observado	Residuo Óptimo	Residuo Forecast
2008-12-31	74.000000	NaN	74	0.000	NaN
2009-01-31	127.044647	201.870616	148	20.955	-53.871
2009-02-28	516.394061	218.349640	8	-508.394	-210.350
2009-03-31	755.152514	666.919279	64	-691.153	-602.919
2009-04-30	890.114314	824.911936	436	-454.114	-388.912
2009-05-31	2014.851270	1406.446553	2627	612.149	1220.553
2009-06-30	2708.245392	1256.178392	972	-1736.245	-284.178
2009-07-31	1725.683297	1262.636919	1474	-251.683	211.363
2009-08-31	1164.246972	1259.408611	3161	1996.753	1901.591
2009-09-30	1326.790929	736.647934	1190	-136.791	453.352
2009-10-31	700.859962	307.230864	155	-545.860	-152.231
2009-11-30	-280.562207	340.113522	51	331.562	-289.114

Cuadro 21: *Elaboración Propia*. Comparación entre el pronóstico óptimo actualizado, el método forecast actualizado, los valores reales y sus residuos.




Figura 33: *Elaboración Propia*. Comparación de Actualización de Pronóstico con Método Forecast

Se puede notar que ambos se acercan más al valor real una vez actualizados, ya que sus residuos son más pequeños esta vez. No hay uno que sea significativamente mejor que el otro luego de la actualización de pronóstico, ya que hay meses en los que el método forecast se acerca más que el método de actualización de pronóstico y viceversa.

3 Conclusiones

Aunque es cierto que la precipitación mensual tiene estacionalidad cada 12 meses y una estacionariedad general, no se pudo encontrar un modelo adecuado que cumpliera todos los supuestos.

El modelo que se entrenó sin transformación tuvo como ventaja que no se alteró la distribución original, su desventaja crítica es que los residuos no cumplen normalidad, lo que invalida intervalos de confianza. Como sus residuos presenten colas pesadas, los residuos extremos estarán subestimados, (como se observa en la Figura 26 y 29, donde una observación real queda fuera del intervalo al 95 %) demostrando que no se puede confiar plenamente en los intervalos de confianza de este modelo. Sin embargo, aunque no cumple el supuesto de normalidad en, se siguen teniendo pronósticos óptimos cercanos a la realidad.

El modelo entrenado con la serie que tiene la transformación Yeo–Johnson tiene como ventaja que los residuos sí cumplen normalidad, sus desventajas residuales son la no independencia y la falta de heterocedasticidad, donde la amplitud de los residuos varía a lo largo del tiempo, esto significa que seguimos violando supuestos de independencia y varianza constante, por lo que los residuos de predicción no son verdaderamente ruido blanco, además de todavía contener información importante sobre la serie. Tampoco se puede confiar absolutamente en estos intervalos de confianza en el pronóstico, ya que asumen varianza constante, de modo que los intervalos de confianza pueden ser demasiado estrechas o demasiado anchas en distintas épocas, lo que también compromete la validez de la inferencia.

El método forecast y el método de pronóstico óptimo con esperanzas condicionales son herramientas capaces de predecir el comportamiento de la serie de tiempo. El pronóstico óptimo basado en esperanzas condicionales tiende a capturar con mayor fidelidad los picos extremos y a ofrecer ajustes más coherentes con los parámetros estimados, frente al método forecast. Esto hace que, en aplicaciones donde la interpretabilidad y la lógica del modelo sean prioritarias, se prefiera el pronóstico óptimo.

Para tener un modelo plenamente confiable, se tendría que encontrar un mejor ARIMA que capture toda la temporalidad de la serie. Ninguno de los dos enfoques cumple con todos los supuestos que un modelo debería tener; el modelo sin transformación falla en normalidad y el modelo con transformación incurre en dependencia, heterogeneidad de varianza, y su media. Para alcanzar un modelo plenamente confiable, será necesario explorar especificaciones más parsimoniosas que satisfagan simultáneamente los requisitos de normalidad, independencia y homocedasticidad de los residuos, sin sacrificar la capacidad predictiva.

4 Referencias

In-Kwon Yeo, Richard A. Johnson, A new family of power transformations to improve normality or symmetry, *Biometrika*, Volume 87, Issue 4, December 2000, Pages 954–959, <https://doi.org/10.1093/biomet/87.4.954>

National Centers for Environmental Information. (2018). GHCN monthly precipitation dataset (version 4). NOAA. <https://www.ncei.noaa.gov/data/ghcnm/v4/precipitation/>